POLITECHNIKA MORSKA
W SZCZECINIE

Wydział:
Informatyki i Telekomunikacji

Data pobrania tematu .....
Data zdania pracy .....

PRACA DYPLOMOWA INŻYNIERSKA

Dyplomant	Mateusz Podolak	Nr albumu: 29965
Specjalność		
Promotor	dr. hab. inż. Paweł Ziemba prof. PM	**Ocena:**
Recenzent		**Ocena:**
Egzamin dyplomowy - data		

TEMAT:

Model predykcyjny indeksów giełdowych z użyciem głębokiego uczenia oraz przetwarzania języka naturalnego

Dyplomant Promotor Dziekan

……..…… ……..…… ……..……

POLITECHNIKA MORSKA W SZCZECINIE
WYDZIAŁ INFORMATYKI
I TELEKOMUNIKACJI

Mateusz Podolak

Model predykcyjny indeksów giełdowych z użyciem głębokiego uczenia oraz przetwarzania języka naturalnego

Predictive model for stock market indices using deep learning and natural language processing

Praca inżynierska napisana

pod kierunkiem

dr. hab. inż. Pawła Ziemby prof. PM

Szczecin 2026

Oświadczenie

Oświadczam, że praca została sporządzona samodzielnie, tj. poza niezbędnymi konsultacjami nie korzystano z pomocy osób trzecich, a w szczególności nie zlecano opracowania pracy lub jej części innym osobom, jak również wszystkie wykorzystane podczas pisania pracy źródła literaturowe zostały podane do wiadomości. Jednocześnie potwierdzam, że:

- Wszelkie fragmenty pracy, w których wykorzystano narzędzia generatywnej sztucznej inteligencji (np. do generowania ilustracji, analizy danych źródłowych, czy wsparcia redakcyjnego), zostały wyraźnie oznaczone i opisane.
- Użycie wspomnianych narzędzi odbyło się wyłącznie za uprzednią zgodą promotora, a ich rezultaty stanowiły jedynie pomoc przy opracowywaniu wybranych elementów pracy, nie wpływając na ostateczny autorski wkład.
- Pozostała część pracy została przygotowana samodzielnie, bez nieuprawnionego wykorzystania narzędzi do generowania treści.

Data ..... Podpis .....

Oświadczenie

Oświadczam, że praca została sporządzona samodzielnie, tj. poza niezbędnymi konsultacjami nie korzystano z pomocy osób trzecich, a w szczególności nie zlecano opracowania pracy lub jej części innym osobom, jak również wszystkie wykorzystane podczas pisania pracy źródła literaturowe zostały podane do wiadomości. Jednocześnie oświadczam, że nie korzystano z narzędzi generatywnej sztucznej inteligencji do generowania i analizy danych, sporządzania ilustracji, analizy tekstów źródłowych czy wsparcia redakcyjnego.

Data ..... Podpis .....

Oświadczenie

Wyrażam zgodę / nie wyrażam zgody* na udostępnianie mojej pracy w Czytelni Biblioteki Głównej Politechniki Morskiej w Szczecinie lub Archiwum Politechniki Morskiej w Szczecinie.

Data ..... Podpis .....

[*] niepotrzebne skreślić

Spis treści

Spis treści ... 7
Wykaz skrótów ... 9
Wykaz symboli ... 11
Wstęp ... 12
1. Podstawy analizy rynków finansowych w kontekście prognozowania krótkoterminowego ... 13
1.1. Charakterystyka rynków finansowych ... 13
1.2. Analiza techniczna w prognozowaniu krótkoterminowym ... 15
1.3. Sentyment rynkowy jako dodatkowe źródło informacji predykcyjnej ... 17
2. Metody modelowania danych sekwencyjnych i tekstowych w uczeniu maszynowym ... 20
2.1. Szeregi czasowe jako dane wejściowe modeli predykcyjnych ... 20
2.2. Rekurencyjne sieci neuronowe i problem długoterminowych zależności ... 22
2.3. Architektura i właściwości sieci LSTM ... 24
2.4. Modele językowe w analizie tekstów finansowych ... 28
3. Charakterystyka danych oraz formalizacja zadania predykcyjnego ... 30
3.1. Charakterystyka i źródła wykorzystanych danych ... 30
3.2. Inżynieria cech dla modeli sekwencyjnych ... 32
3.3. Definicja zmiennej celu oraz horyzontu predykcji ... 46
3.4. Podział danych na zbiory treningowe, walidacyjne oraz testowe ... 48
4. Realizacja modeli predykcyjnych opartych o architekture LSTM ... 50
4.1. Architektura modeli sekwencyjnych ... 50
4.2. Przetwarzanie danych wejściowych oraz konfiguracja procesu uczenia ... 52
4.3. Ocena jakości predykcji modeli sekwencyjnych ... 56
5. Badanie skuteczności prognozowania modeli i analiza wyników ... 62
5.1. Metodologia inferencji ... 62
5.2. Strategie łączenia modeli predykcyjnych ... 64
5.3. Prezentacja oraz intepretacja uzyskanych rezultatów ... 67
Zakończenie ... 77
Streszczenie w języku polskim ... 79
Streszczenie w języku angielskim ... 80
Bibliografia ... 83
Spis rysunków ... 85
Spis tabel ... 87
Załącznik 1. Płyta CD. Kody źródłowe aplikacji: moduł przygotowawczy, moduł główny ... 89

Wykaz skrótów

Skrót	Określenie	
	Język angielski	Język polski
AAPL	Apple Inc. (ticker symbol)	symbol giełdowy Apple
ADX	Average Directional Index	średni indeks kierunkowy
Adam	Adaptive Moment Estimation	adaptacyjna estymacja momentów
AILLIQ	Amihud Illiquidity	wskaźnik niepłynności Amihuda
AMZN	Amazon Inc. (ticker symbol)	symbol giełdowy Amazon
API	Application programming interface	interfejs programowania aplikacji
ATR	Average True Range	średni rzeczywisty zakres wahań
AVWAP	Anchored Volume Weighted Average Price	zakotwiczona średnia cena ważona wolumenem
BERT	Bidirectional Encoder Representations from Transformers	dwukierunkowe reprezentacje koderów z transformerów
BPTT	Backpropagation Through Time	propagacja wsteczna przez czas
DM	Directional Movement	ruch kierunkowy
ECE	Expected Calibration Error	oczekiwany błąd kalibracji
EDT	Eastern Daylight Time	wschodni czas letni
EODHD	End of Day Historical Data	-
EST	Eastern Standard Time	wschodni czas standardowy
F1	F1-score	miara F1 (jakości klasyfikacji)
FinBERT	Financial Bidirectional Encoder Representations from Transformers	BERT dostosowany do domeny finansowej
FNN	Feedforward Neural Network	jednokierunkowa sieć neuronowa
GELU	Gaussian Error Linear Unit	Gaussowska liniowa jednostka błędu
GOOGL	Alphabet Inc. (ticker symbol)	symbol giełdowy Alphabet
JSON	JavaScript Object Notation	format zapisu danych JavaScript
KER	Kaufman Efficiency Ratio	wskaźnik efektywności Kaufmana
LSTM	Long Short-Term Memory	-
MASSI	Mass Index	wskaźnik masy
META	Meta Platforms Inc. (ticker symbol)	symbol giełdowy Meta
MSFT	Microsoft Corporation (ticker symbol)	symbol giełdowy Microsoft
NLP	Natural Language Processing	przetwarzanie języka naturalnego
NVDA	NVIDIA Corporation (ticker symbol)	symbol giełdowy NVIDIA
OHLC	Open, High, Low, Close	otwarcie, maksimum, minimum, zamknięcie
OHLCV	Open, High, Low, Close, Volume	otwarcie, maksimum, minimum, zamknięcie, wolumen
PnL	Profit and Loss	zysk i strata
PVO	Percentage Volume Oscillator	procentowy oscylator wolumenu
PVOH	Percentage Volume Oscillator Histogram	histogram procentowego oscylatora wolumenu

ReLU	Rectified Linear Unit	prostowana jednostka liniowa
RNN	Recurrent Neural Network	rekurencyjna sieć neuronowa
RSI	Relative Strength Index	wskaźnik względnej siły
S&P 500	Standard & Poor's 500 Index	indeks Standard & Poor's 500
SKEW	Rolling Skewness	krocząca skośność rozkładu
SMA	Simple Moving Average	prosta średnia krocząca
TSLA	Tesla Inc. (ticker symbol)	symbol giełdowy Tesla
UTC	Coordinated Universal Time	uniwersalny czas koordynowany
VWAP	Volume Weighted Average Price	średnia cena ważona wolumenem

Wykaz symboli

Skrót	Określenie	
	Język angielski	Język polski
$softmax$	Softmax function	funkcja softmax
$sign$	Signum function	funkcja signum
$tanh$	Hyperbolic tangens	tangens hiperboliczny
$wilder$	Welles Wilder smoothing	wygładzenie wykładnicze Wildera
σ	Sigmoid function	funkcja sigmoidalna
$\odot$	Hadamard product	iloczyn Hadamarda

Wstęp

Prognozowanie kierunku krótkoterminowych zmian cen instrumentów finansowych stanowi jeden z trudniejszych problemów klasyfikacyjnych, co wynika ze złożonej i niejednorodnej natury rynków finansowych.

Celem niniejszej pracy jest zaprojektowanie i implementacja systemu predykcyjnego, który pozwoli zmierzyć się z tym wyzwaniem poprzez połączenie modeli sekwencyjnych opartych na architekturze LSTM z komponentem analizy sentymentu zrealizowanym za pomocą modelu FinBert.

Głównym przedmiotem badania jest sprawdzenie fundamentu zaproponowanego systemu, czyli zdolności modeli uczenia głębokiego do ekstrakcji sygnałów z samych szeregów czasowych. Stąd hipoteza główna zakłada, że modele sekwencyjne wykorzystujące historyczne dane cenowe potrafią uchwycić krótkoterminowe zależności rynkowe w stopniu wystarczającym do osiągnięcia trafności predykcji wyższej niż przypadkowa klasyfikacja.

Zastosowane podejście, łączące modele sekwencyjne z komponentem przetwarzania języka naturalnego, umożliwia jednocześnie przeprowadzenie badań wpływowych. Pierwsza z hipotez pobocznych zakłada, że łączenie predykcji modeli klasyfikacyjnych trenowanych na różnych interwałach czasowych odpowiednio dobraną metodą zwiększa jakość predykcji względem pojedynczych modeli. Druga z nich zakłada, że uwzględnienie informacji tekstowych w procesie łączenia predykcji modeli predykcyjnych wpływa pozytywnie na skuteczność krótkoterminowej klasyfikacji kierunku zmian cen względem systemów opartych wyłącznie o dane rynkowe.

Praca składa się z pięciu rozdziałów. Rozdział pierwszy i drugi stanowią podstawę teoretyczną, omawiając charakterystykę rynków finansowych, analizę techniczną, sentyment rynkowy oraz metody modelowania danych sekwencyjnych i tekstowych w uczeniu maszynowym. Rozdział trzeci skupia się na właściwym podejściu do problemu klasyfikacji przedstawiając przyjęte podejście metodologiczne oraz opisując proces inżynierii cech od strony technicznej. Rozdział czwarty stanowi bazę pracy, opisując proces tworzenia oraz ocene jakości modeli sekwencyjnych. Rozdział piąty przedstawia metodologię oraz wyniki badania skuteczności wypracowanego systemu predykcyjnego. Opisuje proces inferencji łączącej sygnały obu modeli sekwencyjnych z komponentem analizy sentymentu opartym na modelu FinBERT.

1. Podstawy analizy rynków finansowych w kontekście prognozowania krótkoterminowego

1.1. Charakterystyka rynków finansowych

Rynki finansowe stanowią jeden z kluczowych fundamentów współczesnego kapitalizmu. Umożliwiają transfer kapitału pomiędzy podmiotami, dzięki czemu inwestorzy mogą lokować swoje oszczędności w instrumentach finansowych, a przedsiębiorstwa pozyskiwać środki na inwestycje, rozwój działalności lub utrzymanie płynności. Mechanizm ten sprzyja efektywniejszej alokacji zasobów w gospodarce, ogranicza długotrwałe „zamrożenie" kapitału oraz znacząco wspiera wzrost gospodarczy.

Sprawne funkcjonowanie rynków finansowych wymaga współdziałania miejsc obrotu instrumentami finansowymi, sieci instytucji pośredniczących oraz odpowiednich ram regulacyjnych. Miejsca obrotu, czyli giełdy i platformy elektroniczne, umożliwiają zawieranie transakcji i kształtowanie cen. Instytucje pośredniczące, takie jak banki, domy maklerskie czy fundusze inwestycyjne, zapewniają uczestnikom dostęp do instrumentów oraz płynność aktywów. Ramy regulacyjne z kolei, poprzez nadzór publiczny, ograniczają nadużycia, zwiększają przejrzystość i budują zaufanie wśród inwestorów. Wzajemne powiązanie tych trzech warstw tworzy stabilny i efektywny system finansowy[1].

Mechanizm funkcjonowania rynków finansowych opiera się na relacji popytu i podaży. Cena instrumentu w danym momencie jest wynikiem równowagi między gotowością kupujących do płacenia określonej kwoty a skłonnością sprzedających do zbycia aktywów po tej cenie. Gdy popyt przewyższa podaż, ceny rosną, natomiast nadmiar podaży prowadzi do spadków[2]. Ta pozorna prostota, w połączeniu z łatwym dostępem do platform inwestycyjnych, przyciąga bardzo zróżnicowane grono inwestorów nastawionych na wspólny cel - pomnożenie kapitału.

Podstawowy mechanizm generowania zysku na rynkach finansowych polega na wykorzystaniu różnicy cen w czasie. Inwestor zajmuje pozycję długą (kupno) lub krótką (sprzedaż) po określonej cenie, a następnie zamyka ją w późniejszym momencie, realizując zysk gdy cena zmieniła się w kierunku korzystnym lub stratę w przeciwnym przypadku. Pozornie prosta zasada "kup taniej, sprzedaj drożej" w rzeczywistości wymaga identyfikacji złożonych zależności, które mogłyby sygnalizować przyszłe ruchy, stanowiąc istotne wyzwanie dla inwestorów.

Dominującym segmentem rynków finansowych, który przyciąga zdecydowanie najwięcej osób jest rynek kapitałowy, na którym obrót dotyczy m.in. akcji. W ujęciu teoretycznym cena akcji w danym momencie powinna odzwierciedlać wszystkie dostępne informacje dotyczące spółki i jej otoczenia. Pogląd ten jest spójny z założeniami hipotezy

rynku efektywnego, według której ceny "w pełni odzwierciedlają" dostępne informacje **Error! Reference source not found.**. Zgodnie z tą hipotezą wszelkie odchylenia cen od wartości fundamentalnych powinny być natychmiast eliminowane przez uczestników rynku podejmujących działania arbitrażowe. W konsekwencji, systematyczne uzyskiwanie ponadprzeciętnych stóp zwrotu na podstawie powszechnie dostępnych danych powinno być bardzo trudne, a wręcz niemożliwe - według skrajnego wariantu hipotezy Fama.

Dynamika cen bywa jednak bardziej złożona niż wynikałoby to z modelu idealnej efektywności. Ilustracją może być przypadek Royal Dutch/Shell, czyli dwóch klas akcji tej samej spółki, które przez dekady były notowane z odchyleniami od teoretycznego parytetu cenowego sięgającego 35%, mimo że obie były wysoce płynne i łatwo dostępne dla inwestorów[4]. Kluczowe pytanie dotyczy tego, dlaczego takie odchylenia mogą utrzymywać się w czasie, zamiast zostać natychmiast zniwelowane przez arbitraż, jak zakładałaby teoria rynku efektywnego. Jedną z odpowiedzi są ograniczenia arbitrażu. W praktyce arbitraż wymaga kapitału i wiąże się z ryzykiem, a jego skuteczność może spadać szczególnie wtedy, gdy ceny silnie odbiegają od wartości fundamentalnych. Co więcej, arbitrażysta zarządzający cudzym kapitałem może zostać zmuszony do likwidacji pozycji ze stratą zanim nastąpi konwergencja cen, jeśli inwestorzy wycofają środki w reakcji na krótkoterminowe straty[5]. W rezultacie mechanizm arbitrażu nie zawsze działa natychmiastowo i bezbłędnie, co otwiera przestrzeń dla powstawania i utrzymywania się anomalii cenowych.

Równie istotnym czynnikiem ograniczającym efektywność rynku jest niejednorodność uczestników. Giełda nie jest środowiskiem jednolitego inwestora, lecz przestrzenią, w której współistnieją podmioty o odmiennych celach, strategiach i przekonaniach. Część inwestorów opiera decyzje na analizie fundamentalnej oraz dłuższym horyzoncie inwestycyjnym. Obok nich funkcjonują inwestorzy krótkoterminowi oraz spekulanci podejmujący decyzje o podwyższonym poziomie ryzyka, przypominające zachowania hazardowe. Ta różnorodność celów i metod oznacza, że każdy uczestnik reaguje inaczej na te same informacje, co dodatkowo utrudnia szybką korektę odchyleń.

Wypadkową takiej struktury jest to, że obserwowany szereg czasowy cen stanowi rezultat nakładających się procesów działających w różnych skalach czasowych. W krótkim okresie dominować mogą czynniki płynnościowe i zachowania stadne, podczas gdy w dłuższym horyzoncie większe znaczenie mają fundamenty ekonomiczne. To nakładanie się wpływów tworzy przestrzeń dla analizy krótkoterminowej, ponieważ jeśli rynek nie jest w pełni efektywny, mogą pojawiać się przejściowe zależności i powtarzalne reakcje na bodźce stanowiące podstawę poszukiwania i wykorzystywania anomalii cenowych.

1.2. Analiza techniczna w prognozowaniu krótkoterminowym

W rozdziale 1.1 wskazano, że obserwowany przebieg cen jest wypadkową nakładających się procesów działających w różnych skalach czasowych. Od reakcji płynnościowych i mikrostrukturalnych w krótkim okresie, po wolniejsze dostosowania związane z fundamentami i oczekiwaniami w horyzoncie długim. Podkreślono również niejednorodność uczestników rynku oraz fakt, że nawet jeśli ceny w ujęciu teoretycznym powinny odzwierciedlać dostępne informacje, w praktyce mogą występować krótkotrwałe odchylenia od idealnej efektywności. Z tej perspektywy analiza techniczna nie jest alternatywą dla rozumienia rynku, lecz narzędziem, które pozwala uchwycić i opisać te krótkookresowe regularności, zanim zostaną wygładzone przez uczestników rynku.

Analiza techniczna operuje w ramach modelu opisującego dynamikę rynku poprzez trzy podstawowe stany przedstawione na rysunku 1.1. Trend wzrostowy, konsolidację oraz trend spadkowy. Trend wzrostowy charakteryzuje się sekwencją coraz wyższych szczytów i dołków, co wskazuje na przewagę popytu. Konsolidacja występuje wówczas, gdy cena porusza się w ograniczonym zakresie bez wyraźnego kierunku, odzwierciedlając względną równowagę pomiędzy kupującymi a sprzedającymi. Trend spadkowy przejawia się serią coraz niższych szczytów i dołków, sygnalizując dominację podaży[6]. Taki podział stanowi użyteczną aproksymację dynamiki rynku i tworzy ramy interpretacyjne dla jej narzędzi.

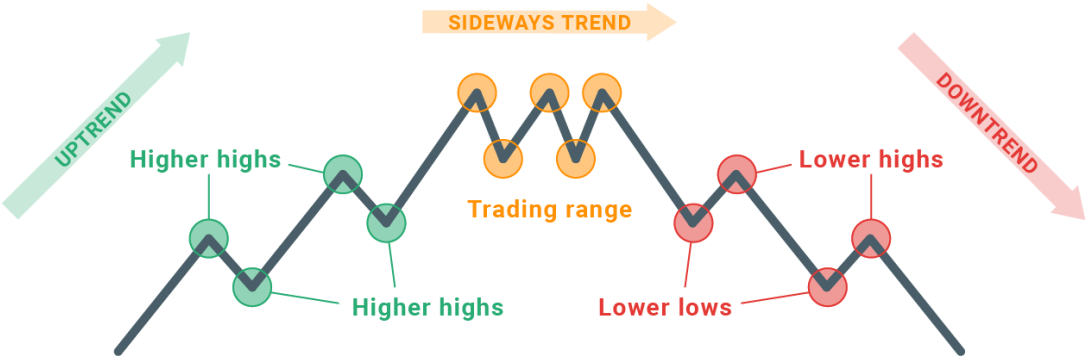

Rysunek 1.1. Schemat trzech stanów rynku: wzrostu, konsolidacji i spadku
Źródło: [34]

Dla inwestora krótkoterminowego kluczowe jest możliwie wczesne rozpoznanie przejścia rynku między stanami przedstawionymi na rysunku 1.1, w szczególności wybicia z konsolidacji, inicjacji trendu oraz pojawienia się przesłanek jego wygasania. W ujęciu krótkoterminowym celem nie jest prognozowanie dokładnego poziomu przyszłej ceny, lecz identyfikacja warunków, które zwiększają prawdopodobieństwo ruchu w określonym kierunku, maksymalizując tym samym ewentualny zysk z zawartej pozycji.

Warunków tych poszukuje się w szeregach czasowych notowań świecowych opisujących cenę otwarcia, maksimum, minimum oraz zamknięcia danego interwału czasowego (ang. open, high, low, close - OHLC), często uzupełnionych o wolumen oraz inne informacje transakcyjne. Narzędziem służącym do ich identyfikacji jest analiza techniczna, rozumiana jako matematyczne modelowanie danych rynkowych oraz konstruowanie wskaźników, które przekształcają surowe dane OHLCV w mierzalne zmienne opisujące bieżący stan rynku[6].

Konstruowane w ten sposób wskaźniki grupuje się według pytania diagnostycznego, na które odpowiadają, przy czym każda z grup dostarcza informacji istotnych zarówno dla rozróżniania stanów rynku, jak i identyfikacji momentów przejścia między nimi. Do najczęściej wykorzystywanych grup należą:

- Trend – miary oparte na średnich kroczących lub nachyleniu dopasowanej prostej/regresji w zadanym horyzoncie, mające na celu identyfikację bieżącego kierunku ruchu.
- Poziomy wsparcia i oporu – obszary cenowe, w których historycznie występowała podwyższona aktywność popytu lub podaży, co prowadziło do zatrzymania bądź odwrócenia ruchu.
- Momentum – miary dynamiki zmian ceny wykorzystywane do oceny, czy ruch ma potencjał kontynuacji, czy też występują przesłanki osłabienia i ryzyka korekty.
- Wolumen – miary aktywności rynku pełniące funkcję filtra jakości sygnału. Ruchy potwierdzone podwyższonym wolumenem bywają interpretowane jako bardziej wiarygodne niż te przy niskiej aktywności.
- Zmienność – miary typowej skali wahań w danym oknie czasowym wykorzystywane do oceny warunków rynkowych filtrowania sygnałów oraz dopasowania parametrów zarządzania ryzykiem.
- Płynność i mikrostruktura – miary warunków realizacji transakcji wykorzystywane jako filtr sygnałów i ograniczenie handlu w okresach podwyższonego ryzyka.

Analiza techniczna stanowi zatem sformalizowane podejście do prognozowania krótkoterminowego, w którym mierzalne cechy szeregu czasowego cen służą do wykrywania powtarzalnych wzorców interpretowanych jako symptomy określonego stanu rynku lub jego zmiany. Skuteczność tego podejścia opiera się na założeniu, że zachowania uczestników rynku, mimo swojej złożoności, wykazują pewną regularność uwidaczniającą się w danych cenowych i wolumenowych, zanim zostanie ona zniwelowana przez mechanizmy

korygujące. Sama analiza danych cenowych i wolumenowych nie wyczerpuje jednak wszystkich źródeł informacji predykcyjnej, ponieważ krótkoterminowa dynamika rynku kształtowana jest również przez nastroje jego uczestników.

1.3. Sentyment rynkowy jako dodatkowe źródło informacji predykcyjnej

Niejednorodność uczestników rynku oraz odchylenia od idealnej efektywności omówione w rozdziale 1.1 oznaczają, że proces wyceny nie zawsze ma charakter w pełni analityczny. Decyzje inwestycyjne zapadają w warunkach niepewności i presji czasu, co sprzyja stosowaniu uproszczonych heurystyk oraz reakcji emocjonalnych. W efekcie rośnie podatność na zachowania stadne i nadreakcje na bodźce informacyjne, szczególnie w okresach podwyższonej zmienności. Z tego względu uzasadnione jest traktowanie nastrojów inwestorów jako mierzalnego czynnika, który może wnosić dodatkową informację predykcyjną.

W literaturze finansów behawioralnych sentyment rynkowy rozumie się zwykle jako zbiorczy nastrój inwestorów (optymistyczny bądź pesymistyczny), który wpływa na ich percepcję ryzyka, selekcję informacji oraz skłonność do podejmowania decyzji inwestycyjnych[7]. W odróżnieniu od klasycznych ujęć efektywnego rynku, gdzie ceny mają natychmiast i w pełni odzwierciedlać informacje fundamentalne, podejście behawioralne dopuszcza, że nastroje mogą generować komponent pozafundamentalny w wycenie aktywów. Oznacza to, że ceny mogą czasowo odchylać się od wartości uzasadnionej danymi ekonomicznymi, ponieważ część uczestników rynku reaguje nie tylko na fakty, lecz także na ich interpretacje, narracje medialne oraz emocje zbiorowe. W krótkim horyzoncie ma to szczególne znaczenie, ponieważ emocje mogą wzmacniać ruchy cen poprzez paniczną podaż lub euforyczny popyt, zanim nastąpi późniejsza korekta wynikająca z powrotu do bardziej „chłodnej” wyceny.

Rolę oraz skale jaką sentyment odgrywa na rynkach finansowych, dobrze ilustruje zestawienie dwóch krzywych przedstawione na rysunku 1.2. Czerwona linia obrazuje poziom pesymizmu, natomiast biała odpowiada rzeczywistej cenie indeksu S&P 500 w tych samych krokach czasowych. Widoczne jest, że epizodom silniejszych korekt cenowych zwykle towarzyszą gwałtowne wzrosty pesymizmu, które współwystępują z podwyższoną zmiennością i mogą wzmacniać krótkookresową presję podażową. Szczególnie wyraźnie widać to podczas załamania z marca 2020r. wywołanego pandemią COVID-19, kiedy miara pesymizmu osiągała wartości skrajne, a rynek doświadczał jednego z najszybszych spadków w swojej historii. Taki mechanizm wzmacniania ruchu cen przez emocje stanowi przykład odchylenia od w pełni racjonalnego procesu wyceny aktywa.

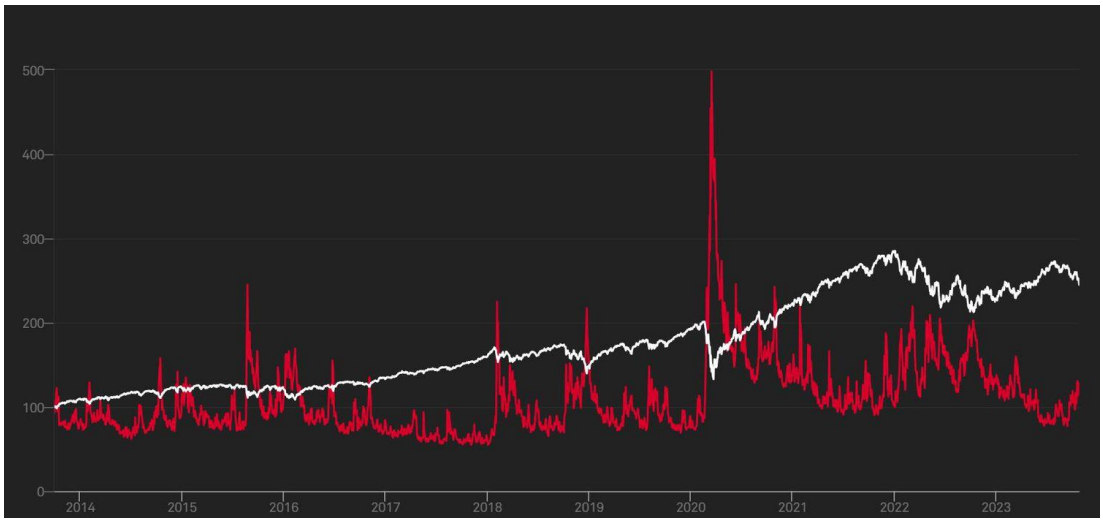

Rysunek 1.2. Korelacja między wskaźnikiem pesymizmu a ceną indeksu S&P500
Źródło: [35]

Jednocześnie to, co z perspektywy inwestora jest odchyleniem od racjonalności, z perspektywy prognozowania krótkoerminowego może być źródłem informacji predykcyjnej. Jeżeli emocje i nastroje nie pojawiają się losowo, lecz reagują w powtarzalny sposób na bodźce, to w danych mogą ujawniać się krótkotrwałe zależności możliwe do ujęcia w postaci mierzalnych zmiennych. Oznacza to, że obok wskaźników technicznych można konstruować miary sentymentu oparte na treści informacji i traktować je jako dodatkowy kanał sygnałowy, szczególnie użyteczny w okresach podwyższonej wrażliwości informacyjnej rynku.

Najbardziej naturalnym nośnikiem sentymentu są wiadomości i komentarze rynkowe, ponieważ współtworzą narrację oraz sposób selekcji i interpretacji faktów przez uczestników rynku. W klasycznym ujęciu Tetlock ilościowo mierzył pesymizm w przekazach prasowych (m.in. na podstawie kolumny rynkowej w The Wall Street Journal) i wykazał, że ton informacji wiąże się z krótkoterminową presją cenową oraz skłonnością rynku do częściowego odwracania wcześniejszego ruchu w kolejnych dniach[8]. Emocjonalny wydźwięk mediów może zatem prowokować lub wzmacniać odchylenia cen od wartości fundamentalnej, po których z opóźnieniem następuje częściowa korekta.

Baker i Wurgler wskazują, że fale optymizmu i pesymizmu szczególnie wpływają na aktywa o bardziej subiektywnej wycenie i większych ograniczeniach arbitrażowych, co sprzyja utrzymywaniu się odchyleń od wartości fundamentalnych przez dłuższy czas[9].

Obie te obserwacje potwierdzają, że sentyment oddziałuje na odchylenia cen od wartości fundamentalnych, zarówno w krótkim okresie (nadreakcje i korekty), jak i w dłuższej perspektywie (utrzymywanie się nieefektywności). Oznacza to, że sentyment rynkowy rozumiany jako mierzalna reakcja inwestorów na napływ informacji może stanowić

uzupełnienie analizy technicznej, dostarczając dodatkowej, możliwej do skwantyfikowania cechy opisującej bieżące warunki rynkowe.

2. Metody modelowania danych sekwencyjnych i tekstowych w uczeniu maszynowym

2.1. Szeregi czasowe jako dane wejściowe modeli predykcyjnych

Standardowe metody uczenia maszynowego, obejmujące jednokierunkowe sieci neuronowe (ang. feedforward neural network, FNN), algorytmy oparte na drzewach decyzyjnych oraz klasyczne modele statystyczne, zostały zaprojektowane z myślą o przetwarzaniu danych w postaci wektorów cech o stałej wymiarowości. W tego typu architekturach każda obserwacja reprezentowana jest przez uporządkowany zbiór atrybutów numerycznych lub kategorycznych wyrażany jako(1), które model analizuje równocześnie, bez rozróżniania ich pozycji w sekwencji czasowej. Przykładowo, w zadaniu klasyfikacji klientów pod kątem ryzyka niespłacenia kredytu, model może wykorzystywać takie cechy jak wysokość dochodów, liczba posiadanych zobowiązań, staż pracy czy historia wcześniejszych opóźnień w płatnościach, traktując je jako równoważne składowe wektora wejściowego.

$$x = [x_1, x_2, x_3, x_4 \dots x_n]^{\mathrm{T}} \in \mathbf{R}^{\mathrm{n}} \tag{1}$$

gdzie:

- x – wektor cech wejśćiowych,
- x_i, – wartość i-tej cechy,
- n – liczba cech,
- $\mathbf{R}^{\mathrm{n}}$ – n-wymiarowa przestrzeń liczb rzeczywistych,

Podejście wektorowe napotyka jednak fundamentalne ograniczenia w przypadku danych, których natura jest z założenia sekwencyjna. Szeregi czasowe rynków finansowych, stanowią reprezentatywny przykład takich struktur. Cena instrumentu finansowego w danym momencie nie jest izolowaną wartością, lecz wynikiem skumulowanych procesów rynkowych rozciągających się na przestrzeni sesji, dni, a nawet tygodni. Inwestor analizujący wykres giełdowy intuicyjnie dostrzega trendy wzrostowe i spadkowe, formacje techniczne, poziomy wsparcia i oporu czy cykliczne wzorce sezonowe. Elementy te, stanowiące fundament analizy technicznej omówionej w rozdziale 1, są jednak zakodowane nie w pojedynczych wartościach, lecz w relacjach między kolejnymi obserwacjami. Model niesekwencyjny, otrzymując wektor zawierający cenę otwarcia, cenę zamknięcia, wolumen oraz kilka wskaźników technicznych z danego dnia, nie jest w stanie samodzielnie wywnioskować, czy obecna cena stanowi kontynuację kilkutygodniowego trendu wzrostowego, czy też nagłe odbicie po serii spadków. Co więcej, rynki finansowe

charakteryzują się niestacjonarnością, zależności statystyczne między zmiennymi ulegają przesunięciom w czasie pod wpływem zmian makroekonomicznych, regulacyjnych czy nastrojów inwestorów. Strategia inwestycyjna skuteczna w okresie hossy może generować straty w czasie bessy, a korelacje między aktywami obserwowane w stabilnych warunkach rynkowych często załamują się w momentach kryzysowych. Dodatkową komplikację wprowadza wskazana w rozdziale 1 niejednorodność uczestników rynku oraz obecność zależności długoterminowych takich jak decyzje banków centralnych podjęte miesiące wcześniej mogą wpływać na dzisiejsze wyceny, a sezonowe wzorce konsumpcji przekładają się na cykliczne zachowania określonych sektorów gospodarki. Tradycyjne podejście wektorowe, agregujące historię do postaci statycznych wskaźników, nieuchronnie prowadzi do utraty informacji o dynamice i kontekście obserwowanych zjawisk.

Odpowiedzią na powyższe ograniczenie są modele sekwencyjne, które uwzględniają uporządkowanie czasowe danych wejściowych. Do najważniejszych architektur tej klasy należą rekurencyjne sieci neuronowe (ang. Recurrent Neural Networks, RNN), ich rozwinięcia w postaci sieci z bramkami LSTM, a także architektury oparte na mechanizmie atencji, w szczególności Transformery. W przeciwieństwie do reprezentacji wektorowej, w której pojedyncza obserwacja jest opisywana przez statyczny zbiór cech, modele sekwencyjne operują na uporządkowanych ciągach obserwacji rozciągniętych w czasie. Oznacza to, że wektorem wejściowym nie jest pojedynczy zestaw cech opisujący jeden moment, lecz sekwencja takich wektorów obejmująca T kolejnych kroków czasowych opisywana jako(2).

$$S = (x_1, x_2, x_3, x_4 \dots x_T), \qquad x_t \in \mathbf{R}^{\mathrm{n}}, \quad t = 1, \dots T \tag{2}$$

gdzie krok t:

$$x_t = [x_{t,1}, x_{t,2}, \dots x_{t,n}]^T \in \mathbf{R}^{\mathrm{n}} \tag{3}$$

gdzie:

S	–	sekwencja wejśćiowa,
$x_t \in \mathbf{R}^{\mathrm{n}}$,	–	wektor cech w kroku czasowym t,
T	–	długość sekwencji,
$x_{t,i}$	–	wartość i-tej cechy w kroku t,

2.2. Rekurencyjne sieci neuronowe i problem długoterminowych zależności

Architekturą, która jako pierwsza zaproponowała bezpośrednie rozwiązanie problemu modelowania danych sekwencyjnych, są rekurencyjne sieci neuronowe.

Kluczowym elementem odróżniającym architekturę RNN od klasycznych sieci jednokierunkowych FNN jest wprowadzenie sprzężenia zwrotnego – połączenia łączącego wyjście warstwy ukrytej z jej wejściem w kolejnym kroku czasowym[10]. Ogólną architekturę podstawowej sieci RNN wraz z mechanizmem sprzężenia zwrotnego przedstawiono na rysunku 2.1. W reprezentacji zwiniętej (lewa strona rysunku) moduł A symbolizuje warstwę ukrytą sieci, która w każdym kroku czasowym przyjmuje wejście x_t i generuje stan ukryty h_t. Pętla prowadząca z wyjścia modułu z powrotem do jego wejścia oznacza, że stan ukryty jest przekazywany do następnego kroku przetwarzania obrazując mechanizm sprężenia zwrotnego. Reprezentacja rozwinięta (prawa strona rysunku) ilustruje ten sam mechanizm w sposób sekwencyjny. Sieć można interpretować jako łańcuch identycznych modułów, z których każdy przekazuje informację do swojego następnika. W kroku t_0 moduł otrzymuje pierwszą obserwację x_0 i generuje początkowy stan ukryty h_0, który następnie jest przekazywany do kroku t_1 wraz z kolejną obserwacją x_1, produkując stan h_1. Proces ten powtarza się dla wszystkich elementów sekwencji aż do ostatniego kroku sekwencji t, w której stan ukryty h_t zawiera skumulowaną informację o całej dotychczasowej historii.

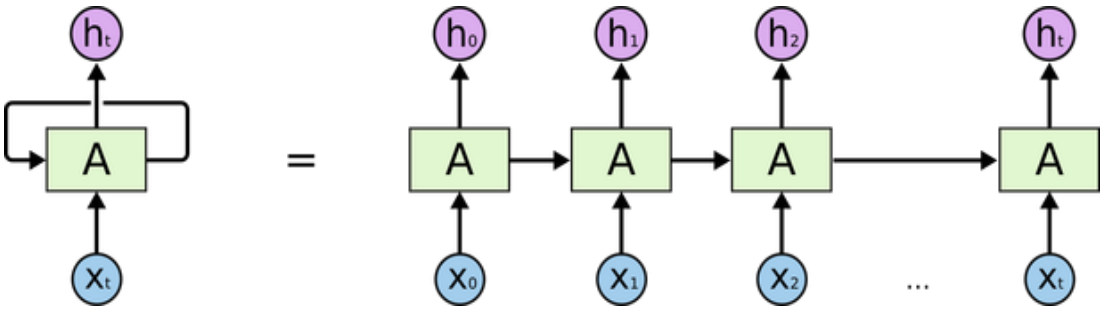

Rysunek 2.1. Architektura prostej sieci RNN
Źródło: [36]

Formalnie, operacja wykonywana przez moduł A, w każdym kroku czasowym przedstawiona we wzorze(4), polega na połączeniu bieżącej obserwacji x_t ze stanem ukrytym z poprzedniego kroku h_{t-1} poprzez transformację liniową, a następnie przekazaniu wyniku przez nieliniową funkcję aktywacji.

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t + b_h) \tag{4}$$

gdzie:

h_t – stan ukryty w kroku *t*,

h_{t-1} – stan ukryty kroku poprzedniego,

x_t – wektor wejściowy w kroku *t*,

W_{hh} – macierz wag połączeń rekurencyjnych,

W_{xh} – macierz wag połączeń wejściowych,

b_h – wektor biasu,

$tanh$ – funkcja aktywacji,

Prostota architekturalna, którą oferuje sieć RNN, wiąże się jednak z istotnymi ograniczeniami ujawniającymi się podczas procesu uczenia. Trenowanie rekurencyjnych sieci neuronowych odbywa się z wykorzystaniem algorytmu propagacji wstecznej przez czas (ang. Backpropagation Through Time, BPTT), który stanowi rozszerzenie klasycznej metody backpropagation na dane sekwencyjne. W podejściu tym sieć jest najpierw rozwijana w czasie – tak jak przedstawiono na rysunku 2.2 a następnie błąd obliczony na wyjściu jest propagowany wstecz przez wszystkie kroki czasowe, umożliwiając aktualizację współdzielonych wag. Kluczowym problemem tej procedury jest sposób, w jaki gradient przepływa przez kolejne kroki czasowe. Podczas propagacji wstecznej sygnał błędu jest w każdym kroku mnożony przez pochodną funkcji aktywacji oraz przez macierz wag rekurencyjnych W_{hh}. Pochodna funkcji tanh przyjmuje wartości z przedziału (0,1], osiągając maksimum równe 1 jedynie dla argumentów bliskich zeru. Oznacza to, że gradient jest wielokrotnie mnożony przez wartości mniejsze od jedynki, co prowadzi do jego wykładniczego zanikania wraz z liczbą kroków czasowych. Zjawisko to, określane jako problem zanikającego gradientu powoduje, że sygnał uczący docierający do początkowych kroków sekwencji staje się znikomo mały[11]. Konsekwencją jest niezdolność sieci do efektywnego uczenia się zależności długoterminowych. Wagi odpowiedzialne za powiązania między odległymi elementami sekwencji nie otrzymują wystarczająco silnego sygnału, przez co pozostają praktycznie niezmienione podczas treningu. W efekcie podstawowa architektura RNN sprawdza się w modelowaniu zależności krótkoterminowych, takich jak wpływ notowań z poprzedniego dnia na bieżącą cenę, natomiast zawodzi w sytuacjach wymagających uwzględnienia kontekstu sprzed dziesiątek kroków czasowych. Ograniczenie to stanowiło główną motywację dla rozwoju bardziej zaawansowanych architektur rekurencyjnych.

2.3. Architektura i właściwości sieci LSTM

Odpowiedzią na problem zanikającego gradientu jest m.in. architektura LSTM (ang. Long Short-Term Memory), zaproponowana przez Hochreitera i Schmidhubera w 1997 roku, która znacząco łagodzi ten problem[12]. Sieć LSTM stanowi rozwinięcie podstawowej architektury RNN, zachowując ideę przetwarzania sekwencyjnego z propagacją informacji między krokami czasowymi, jednocześnie wprowadzając mechanizmy umożliwiające selektywne zapamiętywanie i zapominanie informacji w kontrolowany sposób. Dzięki temu architektura ta jest w stanie efektywnie modelować zależności rozciągające się na dziesiątki, a nawet setki kroków czasowych, co czyni ją odpowiednią do analizy szeregów czasowych rynków finansowych, gdzie istotne zależności mogą rozciągać się na długie horyzonty.

Kluczową innowacją architektury LSTM przedstawionej na rysunku 2.2 jest wprowadzenie dwóch oddzielnych torów przepływu informacji: stanu komórki oznaczanego jako C_t (ang. cell state) pełniącego funkcję pamięci długoterminowej oraz stanu ukrytego h_t (ang. hidden state) odpowiadającego za bieżące przetwarzanie. To właśnie ich rozdzielenie stanowi klucz do znaczącego złagodzenia problemu zanikającego gradientu. Stan komórki przepływa przez kolejne kroki czasowe podlegając jedynie operacjom mnożenia i dodawania, co umożliwia gradientowi propagację wsteczną bez wielokrotnego przechodzenia przez nieliniowe funkcje aktywacji. Przepływ informacji między tymi stanami jest regulowany przez trzy struktury nazywane bramkami. Celem przetwarzania jest wygenerowanie zaktualizowanych stanów C_t oraz h_t, które zostaną przekazane do następnego kroku czasowego, umożliwiając propagację informacji przez całą sekwencję. Aktualizacja ta realizowana jest sekwencyjnie przez poszczególne bramki, z których każda odpowiada za inny aspekt zarządzania pamięcią.

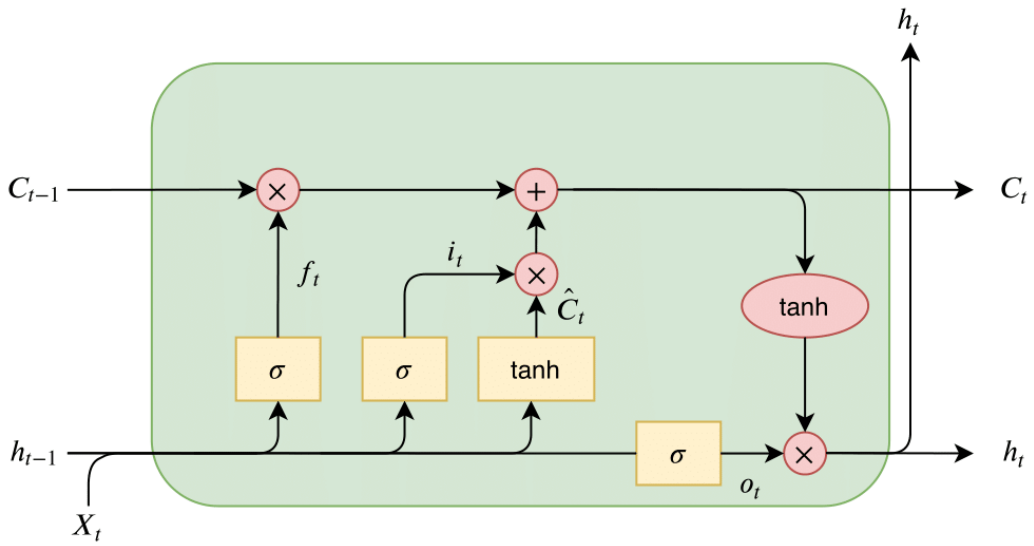

Rysunek 2.2. Architektura komórki lstm
Źródło: [37]

Pierwszym etapem przetwarzania w sieci LSTM jest podjęcie decyzji, które informacje z poprzedniego stanu komórki należy usunąć. Decyzję tę podejmuje bramka zapominania (ang. forget gate), wyrażana wzorem(5), oznaczona symbolem f_t. Bramka ta na podstawie iloczynu konkatenacji bieżącego wektora wejściowego x_t oraz poprzedniego stanu ukrytego h_{t-1} przez wagi generuje wektor wartości z przedziału (0,1) gdzie wartości bliskie 0 oznaczają usunięcie, a bliskie 1 zapamiętanie. To które informacje zachować określają wagi bramki W_f a ograniczenie do tego przedziału realizuje sigmoidalna funkcja aktywacji.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \tag{5}$$

gdzie:

f_t – wyjście bramki zapominania,

σ – sigmoidalna funkcja aktywacji,

W_f – macierz wag bramki zapominania,

h_{t-1} – stan ukryty kroku poprzedniego,

x_t – wektor wejściowy w kroku *t*,

b_f – wektor biasu,

Kolejnym etapem jest określenie, jakie nowe informacje zostaną zapisane w stanie komórki. Proces ten przebiega dwuetapowo. Bramka wejścia (ang. input gate), wyrażana wzorem(6), oznaczana jako i_t, działając analogicznie do bramki zapominania, wyznacza współczynniki w przedziale (0,1), które określają, jaka część informacji zostanie dopisana w każdej składowej stanu. Równolegle, z wykorzystaniem funkcji $tanh$, obliczany jest wektor wartości kandydujących $\widehat{C_t}$ przedstawiony we wzorze(7), opisujący „treść" nowych informacji, które mogą zostać dodane do pamięci.

$$i_t = \sigma(\mathrm{W_i} \cdot [\mathrm{h_{t-1}}, \mathrm{x_t}] + \mathrm{b_i}) \tag{6}$$

$$\widehat{C_t} = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \tag{7}$$

gdzie:

i_t – wyjście bramki wejściowej,

$\widehat{C_t}$ – wektor wartości kandydujących,

$\sigma, \tanh$ – funkcje aktywacji,

$[h_{t-1}, x_t]$ – konkatenacja poprzedniego stanu ukrytego oraz wektora wejściowego,

W_i, W_c – macierze wag,

b_i, b_c – wektory biasu

Aktualizacja stanu komórki wyrażana wzorem(8) jest liczona na podstawie wyjść bramek zapominania oraz wejścia. Poprzedni stan komórki C_{t-1} jest mnożony elementowo przez f_t, usuwając nieistotne informacje, a następnie dodawany jest iloczyn i_t oraz $\widehat{C_t}$, wprowadzając nowe informacje. To właśnie ta addytywna postać aktualizacji umożliwia przenoszenie informacji w czasie z ograniczonym tłumieniem, co ułatwia propagację i zmniejsza problem zanikającego gradientu.

$$C_t = f_t \odot \mathrm{C_{t-1}} + i_t \odot \hat{\mathrm{C}}_\mathrm{t} \tag{8}$$

gdzie:

C_t – nowy stan komórki,

f_t – wyjście bramki forget,

i_t – wyjśćie bramki input

C_{t-1} – poprzedni stan komórki,

$\hat{C}_t$ – wektor kandydatów do nowego stanu komórki,

$\odot$ – iloczyn Hadamarda,

Ostatnim etapem jest wygenerowanie nowego stanu ukrytego h_t, który pełni podwójną rolę. Jest przekazywany do następnego kroku czasowego, a w ostatnim kroku sekwencji może stanowić wyjście modelu wykorzystywane do generowania predykcji. O tym, które informacje ze stanu komórki C_t zostaną uwzględnione w stanie ukrytym, decyduje bramka wyjścia (ang. output gate), wyrażana wzorem(9), oznaczona symbolem o_t, której zasada działania jest analogiczna jak w pozostałych bramkach sieci. Funkcja sigmoidalna ogranicza przedzial do wartosci (0,1) tym samym określając stopień w jakim poszczególne składowe zostaną przekazane dalej. Następnie stan komórki jest przepuszczany przez funkcję $tanh$, która ogranicza jego wartości do przedziału (-1,1) po czym wynik jest mnożony elementowo przez wyjście bramki wyjścia generując stan ukryty.

$$o_t = \sigma(\mathrm{W_o} \cdot [\mathrm{h_{t-1}}, \mathrm{x_t}] + \mathrm{b_o}) \tag{9}$$

$$h_t = o_t \odot \tanh(\mathrm{C_t}) \tag{10}$$

gdzie:

o_t – wyjście bramki wyjściowej,

h_t – nowy stan ukryty,

$\sigma, \tanh$ – funkcje aktywacji,

$[h_{t-1}, x_t]$ – konkatenacja poprzedniego stanu ukrytego oraz wektora wejściowego,

W_o – macierz wag bramki wyjśćiowej,

b_o – wektor biasu bramki wejściowej

Pomimo skutecznego zminimalizowania problemu zanikającego gradientu, architektura LSTM posiada ograniczenie związane ze sposobem agregacji informacji o historii sekwencji. W podstawie, w której predykcja opiera się na reprezentacji końcowej (ostatnim stanie ukrytym h_T) o stałym wymiarze, cała informacja o sekwencji musi zostać w pewnym stopniu skompresowana do pojedynczego wektora. Oznacza to, że przy sekwencji liczącej 10 kroków czasowych model dysponuje taką samą pojemnością pamięci jak przy sekwencji liczącej 100 kroków. Prowadzi to do zjawiska określanego jako wąskie gardło pamięci[13].

Jednym ze sposobów złagodzenia tego ograniczenia jest mechanizm atencji, który umożliwia wykorzystanie informacji z całej sekwencji stanów ukrytych $[h_1, h_2, \dots h_T]$ zamiast polegania wyłącznie na skompresowanej reprezentacji h_T. Mechanizm ten, pierwotnie zaproponowany przez Bahdanau w kontekście tłumaczenia maszynowego[14]. Został następnie szeroko zaadaptowany także w innych zadaniach sekwencyjnych, w tym w analizie szeregów czasowych. Idea atencji polega na dynamicznym przypisywaniu wag poszczególnym krokom sekwencji, które odzwierciedlają ich istotność w kontekście bieżącej predykcji. Wagi te obliczane są na podstawie oceny istotności każdego kroku, wyznaczanej zgodnie ze wzorem:

$$e_t = w^T \tanh(Wh_t + b) \tag{11}$$

$$a_t = \frac{\exp(e_t)}{\sum_{k=1}^{T} \exp(e_k)} \tag{12}$$

gdzie:

h_t – stan ukryty w kroku t,

W, w – macierz wag, wektor wag,

b – wektor biasu,

e_t – ocena istotności kroku t,

e_k – ocena istotnośći kroku k,

Wynikowa reprezentacja kontekstowa stanowi ważoną kombinację wszystkich stanów ukrytych przedstawianą jako:

$$c = \sum_{t=1}^{T} a_t h_t \tag{13}$$

gdzie:

a_t – waga atencji w kroku t,

h_t – stan ukryty w kroku t,

Dzięki temu mechanizmowi model może przypisać wysoką wagę informacji z dowolnego kroku sekwencji, niezależnie od jej odległości czasowej od momentu predykcji.

2.4. Modele językowe w analizie tekstów finansowych

Wczesne podejścia do analizy tekstu w finansach opierały się na metodach słownikowych, w których do klasyfikacji sentymentu dokumentów wykorzystywano predefiniowane listy słów o wydźwięku pozytywnym i negatywnym[15]. Podejście to, choć intuicyjne i proste, w ograniczonym stopniu uwzględnia kontekst oraz specyfikę języka finansowego. Wprowadzenie sieci rekurencyjnych, w tym LSTM, umożliwiło modelowanie tekstowych zależności sekwencyjnie, jednak ich zastosowanie w przetwarzaniu języka naturalnego wiąże się z ograniczeniami wynikającymi z konieczności przetwarzania słów krok po kroku oraz trudnościami w uchwyceniu zależności długodystansowych.

Przełomem w tej dziedzinie okazała się architektura transformer, zaproponowana przez Vaswani i współpracowników w 2017 roku[16]. W przeciwieństwie do sieci rekurencyjnych, transformer rezygnuje z przetwarzania sekwencyjnego na rzecz mechanizmu samo-atencji (ang. self-attention), opisanego wzorem(14), który pozwala modelować zależności między wszystkimi elementami sekwencji równolegle. Mechanizm ten stanowi rozwinięcie koncepcji atencji omówionej w rozdziale 2.3. Podczas gdy atencja w ujęciu Bahdanau wyznacza wektor kontekstowy jako ważoną kombinację stanów ukrytych, samo-atencja buduje reprezentację każdego elementu sekwencji poprzez uwzględnienie informacji pochodzących ze wszystkich pozostałych elementów. Dla każdego elementu sekwencji obliczane są trzy wektory: zapytanie (ang. query), określające jakiej informacji poszukuje dany element, klucz (ang. key), opisujący jaką informację element oferuje, oraz wartość (ang. value), zawierająca właściwą treść do przekazania. Wagi atencji wyznaczane są na podstawie podobieństwa między zapytaniem danego elementu a kluczami wszystkich pozostałych elementów sekwencji, a następnie wykorzystywane do obliczenia ważonej sumy odpowiadających im wartości.

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \tag{14}$$

gdzie:

Q – macierz zapytań,

K – macierz kluczy,

V – macierz wartośći,

d_k – wymiar wektora klucza,

$softmax$ – funkcja aktywacji,

Poza mechanizmem samo-atencji architektura Transformer wprowadza kilka dodatkowych elementów. Do najważniejszych należą wielogłowicowa atencja (ang. multi-head attention), wykonująca równolegle wiele operacji atencji z odrębnymi projekcjami, co

pozwala modelowi jednocześnie wychwytywać różne typy zależności między elementami sekwencji, oraz kodowanie pozycyjne (ang. positional encoding) dodawane do reprezentacji wejściowych, niezbędne ze względu na brak rekurencji, która w sieciach LSTM w sposób naturalny koduje pozycję elementu w czasie. Każdy blok Transformera zawiera ponadto sieć FNN przetwarzającą każdą pozycję niezależnie oraz połączenia rezydualne z normalizacją warstw, stabilizujące proces uczenia głębokich modeli poprzez umożliwienie bezpośredniego przepływu gradientu z pominięciem warstw pośrednich.

Architektura Transformer umożliwiła stworzenie wielkoskalowych modeli językowych trenowanych metodą uczenia transferowego. W 2018 roku Devlin i współpracownicy zaproponowali model BERT (ang. Bidirectional Encoder Representations from Transformers)[17], który zrewolucjonizował przetwarzanie języka naturalnego i do dziś pozostaje fundamentem większości nowoczesnych systemów NLP (ang. natural language processing). Przełomowość BERT wynika z dwóch innowacji. Po pierwsze, model wprowadził dwukierunkowe przetwarzanie kontekstu. W przeciwieństwie do wcześniejszych modeli jednokierunkowych, reprezentacja każdego słowa uwzględnia jednocześnie kontekst poprzedzający i następujący, co pozwala uchwycić znacznie bogatsze zależności semantyczne. Słowo "zamknięcie" rozumiane jest inaczej, gdy poprzedza je "cena akcji" niż gdy następuje po nim "fabryki". Po drugie, BERT wprowadził paradygmat dwuetapowego uczenia. Wstępnego treningu na ogromnym korpusie tekstów ogólnych, podczas którego model uczy się przewidywać losowo zamaskowane słowa w zdaniu (ang. masked language modeling), a następnie dostrajania (ang. fine-tuning) do konkretnego zadania przy użyciu znacznie mniejszego zbioru danych. Dzięki temu raz wytrenowany model można efektywnie zaadaptować do dziesiątek różnych zadań.

Modele językowe trenowane na tekstach ogólnych napotykają jednak na istotne ograniczenie w zastosowaniach finansowych. Język finansowy rządzi się własnymi konwencjami, a wiele słów niesie w nim znaczenie diametralnie różne od potocznego. Model wytrenowany na Wikipedii i książkach widział te słowa zbyt rzadko w finansowym kontekście, by nauczyć się ich domenowego znaczenia. W odpowiedzi na to ograniczenie Yang i współpracownicy opracowali model FinBERT[18], który rozszerza BERT o dodatkowy pre-training przeprowadzony na dużym korpusie tekstów finansowych, obejmującym komunikaty prasowe spółek, raporty analityków oraz artykuły z serwisów branżowych. Ten etap aktualizuje reprezentacje słów tak, by odzwierciedlały ich finansowe użycie. Dopiero na tak przekształconych reprezentacjach przeprowadzany jest fine-tuning do klasyfikacji sentymentu. Dzięki temu FinBERT nie tylko rozpoznaje wydźwięk tekstu, ale rozumie go w finansowym kontekście, co przekłada się na istotnie wyższą skuteczność w zadaniach analizy sentymentu wiadomości rynkowych w porównaniu z modelem bazowym.

3. Charakterystyka danych oraz formalizacja zadania predykcyjnego

3.1. Charakterystyka i źródła wykorzystanych danych

W pracy wykorzystano dwa rodzaje danych. Dane liczbowe w postaci szeregów czasowych składających się z cen instrumentów finansowych oraz odpowiednio dobranych rozszerzeń, a także dane tekstowe w postaci nagłówków i treści wiadomości rynkowych.

Instrumentami finansowymi będącymi przedmiotem badań są akcje spółek notowanych na rynku amerykańskim. Wybór ten jest ściśle podyktowany charakterystyką tego instrumentu. Akcje, mimo iż charakteryzują się zmiennością niezbędną do identyfikacji wzorców, wykazują jednocześnie mniejszą częstość ekstremalnych skoków cenowych i niższą nieprzewidywalność w porównaniu z instrumentami takimi jak kryptowaluty[19]. Stanowią tym samym kompromis między dynamiką cenową umożliwiającą zastosowanie analizy technicznej a przewidywalnością wynikającą z fundamentalnej podstawy wartości.

Rynek akcyjny cechuje się silną korelacją wewnątrz sektorów[190], co ma istotne znaczenie metodologiczne. Trening modelu na spółkach z całkowicie odmiennych branż może utrudniać wykrywanie wspólnych prawidłowości, ponieważ sektory różnią się wrażliwością na czynniki oraz mechanizmami kształtowania cen. Łączenie w jednym zbiorze danych firm z różnych sektorów zwiększałoby poziom szumu, ograniczając zdolność modelu do identyfikacji powtarzalnych zależności. Z tego względu analizą objęto grupę spółek określanych mianem „Magnificent Seven" w skład, której wchodzą spólki takie jak Apple, Microsoft, Alphabet, Amazon, Nvdia, Meta oraz Tesla. Choć nie wszystkie należą do sektora big-tech w ścisłym znaczeniu, łączy je wysoka kapitalizacja, istotny wpływ na główne indeksy giełdowe oraz przynależność do grupy określanej jako akcje wzrostowe (ang. growth stocks). Taki dobór próby ograniczył w pewnym stopniu szum informacyjny. Zarazem zachowując wystarczającą zmienność wewnątrz grupy, by ocenić, jak model radzi sobie na de-facto odmiennych modelach biznesowych w ramach spójnej kategorii rynkowej.

Zakres czasowy danych objął okres od 2020 do 2026 roku. Ograniczenie to wynika z założenia, że rynki finansowe podlegają zmianom strukturalnym wpływającym na mechanizmy kształtowania cen[21]. Włączenie danych z odległych okresów historycznych, mogłoby wprowadzić wzorce, które w obecnych warunkach nie mają już zastosowania, tym samym utrudnić proces uczenia oraz ewaluacji wprowadzając dodatkowy niepotrzebny szum informacyjny.

Dane cenowe analizowano w interwałach 5 oraz 15-minutowych. Wybór ten wynika z założenia przedstawionego w rozdziale 1, że w krótkim okresie dominują czynniki

płynnościowe oraz reakcje behawioralne, natomiast w dłuższym horyzoncie efekty te ulegają wygładzeniu przez napływ informacji fundamentalnych i działania arbitrażystów. Interwały rzędu minut pozwalają na uchwycenie krótkotrwałych nieefektywności i powtarzalnych wzorców wynikających z mikrostruktury rynku, zanim zostaną skorygowane przez uczestników dążących do równowagi cenowej. Jednocześnie interwały 5 i 15-minutowe są wystarczająco długie, by zapewnić odpowiednią płynność transakcyjną oraz ograniczyć wpływ szumu pochodzącego z pojedynczych zleceń czy zdarzeń losowych. Z perspektywy uczenia maszynowego taki zakres czasowy tworzy środowisko, w którym modele mogą identyfikować zależności statystyczne bez nadmiernej ekspozycji na zjawiska charakterystyczne dla handlu wysokoczęstotliwościowego, takie jak efekty składania zleceń czy manipulacje cenowe w skali milisekund[22].

Wszystkie dane wykorzystane w pracy, zarówno szeregi czasowe notowań, jak i nagłówki oraz treści wiadomości rynkowych pozyskano za pośrednictwem interfejsu API serwisu EODHD (End of Day Historical Data). Dane zostały pobrane jednorazowo w formacie JSON dla całego analizowanego okresu i zapisane w plikach .json w celu późniejszej obróbki. Dla danych rynkowych rekord reprezentujący pojedynczą świece z interwału 5-minutowego wygląda następująco:

```
{
  "timestamp": 1739554200,
  "datetime": "2025-02-14 17:30:00",
  "open": 243.824996,
  "high": 243.869705,
  "low": 243.520004,
  "close": 243.539993,
  "volume": 208431
}
```

Dla danych tekstowych każdy rekord odpowiada pojedynczej wiadomości rynkowej i prezentuje się w podany sposób:

```
{
  "timestamp": 1767243619,
  "datetime": "2026-01-01 05:00:19",
  "title": "Apple cuts Vision Pro prod…",
  "content": "Apple has scaled back manufacturing...",
  "link": "https://...",
  "ticker": "AAPL.US"
}
```

Wykorzystanie danych odbyło się zgodnie z warunkami licencji EODHD umożliwiającej zastosowanie ich do celów badawczych i edukacyjnych. Dane zostały użyte wyłącznie do analiz statystycznych oraz budowy modeli predykcyjnych, bez ich dalszego rozpowszechniania w postaci surowej.

3.2. Inżynieria cech dla modeli sekwencyjnych

Surowe dane sekwencyjne pobrane z serwisu EODHD wymagają szeregu przekształceń zanim będą mogły trafić do wektorów wejściowych modeli predykcyjnych. Inżynieria cech stanowi kluczowy etap modułu przetwarzania danych przedstawionego w załączniku 1, ponieważ wpływa zarówno na jakość informacji dostarczanej modelowi, jak i na spójność obserwacji w czasie. W ramach etapu inżynierii cech zrealizowano trzy niezbędne podprocesy:

1. Obsługa brakujących wartości
2. Agregacja danych na wyższe okna czasowe
3. Obliczanie wskaźników technicznych oraz konstrukcja wektora wejściowego modeli sekwencyjnych

Pierwszym podprocesem etapu inżynierii cech jest obsługa brakujących wartości. Ciągłość szeregu czasowego jest istotna nie tylko dla modeli sekwencyjnych, które oczekują regularnie próbkowanych wejść o stałym kroku czasowym, ale również podczas obliczania wskaźników technicznych, które są fundamentem informacji o rynku dla modeli.

Zanim uzupełniono brakujące okna czasowe, dane posortowano rosnąco według czasu, ponieważ API może zwrócić je w kolejności niespójnej chronologicznie. Następnie usunięto brakujące rekordy występujące na początku sekwencji szeregu czasowego. Jest to konieczne, ponieważ dla początkowego fragmentu szeregu nie ma wcześniejszej obserwacji, na podstawie której dałoby się wiarygodnie przeprowadzić wypełnianie. W efekcie takie rekordy nie wnoszą żadnej wartości i są bezużyteczne w dalszych etapach przetwarzania.

```
ticker.Data.Sort((a, b) => a.Timestamp.CompareTo(b.Timestamp));
while (ticker.Data.Count > 0 && IsNullCandle(ticker.Data[0]))
{
 ticker.Data.RemoveAt(0);
}
```

Do wypełnienia brakujących okien czasowych zastosowano metodę forward fill, w której każda luka jest uzupełniana ostatnią znaną wartością. Wybór tej metody wynika z charakteru danych rynkowych. W przypadku brakującej świecy nie da się wiarygodnie odtworzyć przebiegu ceny wewnątrz interwału. Metody interpolacyjne lub wygładzające generowałyby ruch cenowy, który faktycznie nigdy nie wystąpił, fałszując tym samym zdarzenia rynkowe i zaburzając wartości wyliczanych wskaźników technicznych tym samym zmniejszając rzetelność powstałych modeli.

Bezpośrednie przepisanie całej poprzedniej świecy również byłoby problematyczne, ponieważ kopiowanie jej wartości High i Low sugerowałoby zakres wahań, który w rzeczywistości nie miał miejsca. Dlatego wszystkie wartości OHLC brakującej

świecy ustawiono na wartość zamknięcia ostatniej poprawnej świecy, a wolumen na zero. Taka defensywna konstrukcja oznacza brak zmiany ceny w danym kroku czasowym względem poprzedniego, co jest najbardziej zachowawczym założeniem przy braku informacji i minimalizuje ryzyko wprowadzenia sztucznej zmienności. Dodatkowo rekord oznaczono flagą MissingFlag w celu późniejszego odróżnienia go od prawdziwych zdarzeń rynkowych.

```
c.Open = prevClose;
c.High = prevClose;
c.Low = prevClose;
c.Close = prevClose;
c.Volume = 0;
c.MissingFlag = true;
```

Ze względu na przyjęte do badań interwały czasowe 5 i 15-minutowe, oraz fakt, że dane świecowe pobrane z API są w formacie 5-minutowym, następnym podprocesem etapu inżynierii cech jest agregacja danych z interwału 5-minutowego do interwału 15-minutowego.

Przed właściwą agregacją odrzucono wszystkie świece spoza godzin regularnej sesji giełdy amerykańskiej, tj. spoza przedziału 9:30-16:00 czasu Eastern Time. Dane przed i po otwarciu sesji charakteryzują się odmienną dynamiką cenową i znacząco niższą płynnością, co mogłoby zniekształcać wartości wskaźników technicznych obliczanych w następnym etapie oraz utrudniać modelom wykrywanie zależnośći przez nagłe zmiany wolumenu. Konwersja znaczników czasu z formatu Unix (UTC) na czas lokalny giełdy została zrealizowana z uwzględnieniem przejść między czasem standardowym a letnim (EST/EDT), za pomocą funkcji TimeZoneInfo.ConvertTime.

```
private static bool IsRegularSession(Candle c)
{
 var utc = DateTimeOffset.FromUnixTimeSeconds(c.Timestamp);
 var local = TimeZoneInfo.ConvertTime(utc, ExchangeTimeZone);

 return local.TimeOfDay >= MarketOpenLocal
        && local.TimeOfDay < MarketCloseLocal;
}

var sessionData = data.Where(IsRegularSession)
                      .OrderBy(c => c.Timestamp).ToList();
```

Agregacja polegała na grupowaniu kolejnych świec 5-minutowych w kubełki czasowe odpowiadające wyższemu interwałowi, a następnie obliczeniu wartości OHLCV nowo utworzonej świecy.

Każda świeca 5-minutowa została przypisana do odpowiedniego kubełka na podstawie swojej pozycji czasowej względem momentu otwarcia sesji giełdowej. Indeks kubełka obliczono jako iloraz całkowity liczby minut, które upłynęły od otwarcia sesji, przez długości interwału docelowego zgodnie ze wzorem (15).

$$index = \frac{t_{current} - t_{open}}{t_{interval}} \tag{15}$$

gdzie:

$t_{currrent}$ – czas świecy,

t_{open} – czas otwarcia giełdy,

$t_{interval}$ – długość interwału docelowego w minutach,

Dla każdego kubełka tworzono jedną zagregowaną świecę według reguł przedstawionych w Tabeli 3.1.

Tabela 3.1. Reguły agregacji świec z interwału bazowego do wyższego interwału czasowego

Wartość	Reguła agregacji
Open	Cena otwarcia pierwszej świecy w kubeł
High	Maksimum cen ze wszystkich świec z kubełka
Low	Minimum cen ze wszystich świec z kubełka
Close	Cena zamknięcia ostatniej świecy w kubełku
Volume	Sume wolumenów świec w kubełku

Źródło: opracowanie własne

Dodatkowo przyjęto, że każda zagregowana świeca, w której większość danych składowych została sztucznie uzupełniona metodą forward fill, nie odzwierciedla rzeczywistej dynamiki rynku w wystarczającym stopniu i mogłaby wprowadzać fałszywe dane. Dlatego zagregowana świeca dziedziczyła flagę MissingFlag, ustawianą na wartość true, jeśli proporcja brakujących świec składowych do rzeczywistych przekraczała próg 60%, czyli 2/3 dla interwału 15-minutowego.

```
var slice = group.OrderBy(c => c.Timestamp).ToList();

var candle = new Candle
{
 Timestamp = group.key.ToUnixTimeSeconds(),
 Open = slice.First().Open,
 High = slice.Max(c => c.High),
 Low = slice.Min(c => c.Low),
 Close = slice.Last().Close,
 Volume = slice.Sum(c => c.Volume),
 MissingFlag = missingCandles / slice.Count >= 2.0 / 3.0,
};
```

Ostatnim podprocesem etapu inżynierii cech jest przygotowanie cech do wektorów wejściowych modeli, które w możliwie najlepszy sposób opisują aktualną dynamikę rynku. Surowe dane OHLCV nie opisują bezpośrednio stanu rynku w kategoriach przydatnych do predykcji, takich jak siła trendu, poziom zmienności czy presja wolumenowa, niosą jednak w sobie wszystkie istotne o nim informacje. Wskaźniki techniczne pełnią rolę ekstraktorów tych informacji, przekształcając sekwencję cen i wolumenów w zestaw mierzalnych cech opisujących bieżące warunki rynkowe. Dlatego ich definicja jest pierwszym krokiem przygotowania cech wejściowych.

Dobór wykorzystanych wskaźników oparty został o kategorie czynników opisanych w rozdziale 1.2, obejmujących trend, momentum, zmienność, wolumen oraz płynność i mikrostrukturę rynku. Dla każdej kategorii dobrano zestaw wskaźników, które w sposób wyczerpujący opisują dany aspekt analizy technicznej. Mapowanie kategorii teoretycznych na zaimplementowane wskaźniki przedstawiono w Tabeli 3.2. Następnie na ich podstawie zostały skonstruowane cechy wejściowe.

Tabela 3.2. Mapowanie kategorii analizy technicznej na zaimplementowane wskaźniki

Kategoria	Zaimplementowane wskaźniki
Trend, Poziomy wsparcia i oporu	SMA(10, 20, 50)
Momentum	RSI(14), ADX(14), MassIndex(9, 25), KER(10)
Zmienność	ATR(14), Rolling Skewness(20)
Wolumen	Volume ROC, PVOH(12,26,9), VWAP(20), AVWAP
Płynność i mikrostruktura	AmigudILLIQ(20)

Źródło: opracowanie własne

Wskaźnikiem opisującym kategorię trendu, jest prosta średnia krocząca (ang. Simple Moving Average, SMA). Wygładza on krótkoterminowe wahania ceny, uwidaczniając kierunek ruchu w danym horyzoncie. Obliczana jest jako średnia arytmetyczna z n ostatnich cen zamknięcia, wyrażana wzorem (16)[23].

$$SMA_{(n)} = \frac{C_1 + C_2 + \ldots + C_n}{n} \tag{16}$$

gdzie:

n – okres,

C – cena zamknięcia,

Surowa wartość średniej kroczącej nie stanowi użytecznej cechy wejściowej do modelu, jest ona wyrażona w jednostkach cenowych, rośnie i maleje wraz z ceną

instrumentu i nie niesie bezpośredniej informacji o stanie rynku. Istotna jest natomiast relacja bieżącej ceny do średniej. Dlatego skonstruowano cechę opisującą odległość aktualnej ceny zamknięcia od wartości średniej kroczącej według wzoru(17), która jednocześnie wyraża siłę bieżącego trendu oraz sygnalizuje zbliżanie się ceny do poziomu średniej, pełniącej w analizie technicznej rolę dynamicznego poziomu wsparcia lub oporu. Dodatkowo, z relacji średnich o różnych okresach skonstruowano cechy opisujące ich wzajemne położenie, co definiuje zależność(18). Ich zbliżanie się do zera (siebie) sygnalizuje potencjalną zmianę dynamiki, a zmiana znaku odpowiada zjawisku przecięcia średnich kroczących, interpetowanego jako sygnał zmiany kierunku trendu.

$$CloseVsSma_{(n)} = \frac{C}{sma_{(n)}} \tag{17}$$

gdzie:

C – cena zamknięcia,

$sma_{(n)}$ – wartość średniej kroczącej z n okresów,

$$SmaVsSma = \frac{sma_{(n_2)}}{sna_{(n_1)}} \tag{18}$$

gdzie:

$sma_{(n_1)}$ – średnia krocząca z n_1 okresów,

$sma_{(n_2)}$ – średnia krocząca z n_2 okresów,

Kategorie momentum opisują łącznie cztery wskaźniki, których zadaniem jest dostarczenie informacji o dynamice ruchu cenowego, a dokładniej czy bieżący ruch ma potencjał kontynuacji, czy wykazuje oznaki wyczerpania:

- Relative Strength Index (RSI) - mierzy stosunek średnich zysków do średnich strat w zadanym oknie czasowym, wynik mieszczący się w skali od 0 do 100, oblicza się zgodnie ze wzorem(19). Wartości bliskie 0 wskazują na silne wyprzedanie instrumentu, sygnalizując potencjalne odbicie. Natomiast wartości bliskie 100 na ekstremalne wykupienie sygnalizując potencjalny spadek[23].

$$RSI_{(n)} = \frac{100}{1 + RS} \tag{19}$$

gdzie:

n – okres,

RS – iloraz średniego zysku i średniej straty z okresu n,

RSI jest wskaźnikiem bezwymiarowym, a jego formuła zawiera wewnętrzną normalizację i wartość nie zależy od poziomu cenowego instrumentu więc sam w sobie stanowi cechę wejściową opisująca bieżący stan momentum,

- Average Directional Index (ADX) - mierzy siłę bieżącego trendu bez wskazania jego kierunku. Oblicza się go zgodnie ze wzorem(20) jako wygładzoną średnią indeksu kierunkowego, który bazuje na relacji ruchu kierunkowego (+DM, −DM) do True Range. Niskie wartości wskazują na brak wyraźnego trendu, wysokie na silny trend niezależnie od tego czy jest wzrostowy czy spadkowy[23].

$$+DM_t = MAX(H_1 - H_{t-1}, 0), \qquad -DM_t = MAX(L_{t-1} - L_t, 0)$$

$$TR_t = MAX(H_t - L_t, |H_t - C_{t-1}|, |L_t - C_{t-1}|)$$

$$+DI_n = 100\frac{Wilder_n(+DM_t)}{Wilder_n(TR_t)}, \qquad -DI_n = 100\frac{Wilder_n(-DM_t)}{Wilder_n(TR_t)}$$

$$DX_n = 100\frac{|+DI_n - (-DI_n)|}{+DI_n + (-DI_n)}$$

$$ADX_n = AVG(DX_n) \tag{20}$$

gdzie:

t	– krok czasowy,
n	– okres,
H, L, C	– ceny – maksymalna,minimalna,zamknięcia,
$+DM$	– ruch kierunkowy dodatni,
$-DM$	– ruch kierunkowy ujemny,
TR	– rzeczywisty zakres wahań,
$Wilder$r	– wygładzenie wykładnicze Wildera,
$+DI$	– wskaźnik kierunkowy dodatni,
$-DI$	– wskaźnik kierunkowy ujemny,
DX	– indeks kierunkowy,

ADX jest wskaźnikiem bezwymiarowym, jednak w odróżnieniu od RSI jego typowy poziom różni się między instrumentami i okresami, dlatego surowa wartość ADX nie stanowi cechy wejściowej bezpośrednio. Cechę wejściową opartą o ADX wyrażono jako stosunek do własnej średniej kroczącej według wzoru(21),

przedstawiając odchylenie bieżącej siły trendu od jej normy – „silniejszy/słabszy niż zwykle”.

$$ADXRATIO = \frac{ADX_{(n)}}{EMA_{50}(ADX_n)} \tag{21}$$

gdzie:

$ADX_{(n)}$ – ADX z okresu n,

$EMA_{50}(ADX_n)$ – średnia krocząca z 50 ostatnich wartości ADX,

- Mass Index - identyfikuje potencjalne odwrócenia trendu poprzez analizę ściskania i rozszerzania zakresu cenowego. Wskaźnik bazuje na obserwacji, że przed odwróceniem trendu zakres świec ma tendencję do chwilowego rozszerzenia, a następnie gwałtownego ścieśnienia. Mass Index obliczany jest jako krocząca suma stosunków podwójnie wygładzonego zakresu cenowego w oknie n okresów według wzoru(22)[24].

$$Range_t = H_t - L_t$$

$$MASSI_n = \sum_{i=0}^{n} \frac{EMA_9(Range_{t-1})}{EMA_9(EMA_9(Range_{t-1}))} \tag{22}$$

gdzie:

EMA_9 – wykładnicza średnia krocząca z okresu 9,

H, L – cena maksymalna, cena minimalna,

$Range$ – zakres cenowy świecy,

t – krok czasowy,

n – okres,

Podobnie jak ADX, typowy poziom Mass Index różni się między instrumentami, dlatego cechę wejściową wyrażono jako stosunek do własnej średniej kroczącej zgodnie ze wzorem(23), opisując odchylenie bieżącego stanu od jego normy dla danego instrumentu.

$$MASSIRATIO = \frac{MASSI_n}{EMA_{50}(MASSI_n)} \tag{23}$$

gdzie:

$MASSI_{(n)}$ – MASSI z okresu n,

$EMA_{50}(ADX_n)$ – wykładnicza średnia krocząca z 50 ostatnich wartości Massi,

- Kaufman Efficiency Ratio (KER) - mierzy efektywność ruchu cenowego, czyli na ile ruch ceny w danym oknie jest kierunkowy w stosunku do łącznej drogi, jaką cena przebyła. Niskie wartości wskazują na rynek zdominowany szumem, w którym sygnały trendowe z pozostałych wskaźników mogą być mniej wiarygodne. Wysokie wartości wskazują na czysty ruch kierunkowy, w którym sygnały momentum mają większą wartość predykcyjną. KER obliczany jest jako stosunek bezwzględnej zmiany ceny do sumy bezwzględnych zmian jednookresowych w oknie n zgodnie ze wzorem(24)[25].

$$KER_n = \frac{|C_t - C_{t-n}|}{\sum_{i=1}^{n} |C_{t-i+1} - C_{t-1}|} \tag{24}$$

gdzie:

C – cena zamknięcia,

t – krok czasowy,

n – okres,

KER jest wskaźnikiem bezwymiarowym o naturalnie ograniczonym zakresie [0, 1], dlatego sam w sobie stanowi cechę wejściową bez konieczności konstruowania relacji z innymi wielkościami.

Kategorię zmienności opisują dwa wskaźniki, których zadaniem jest dostarczenie informacji o bieżącej skali wahań cenowych, która może nieść za sobą kluczowy kontekst dla interpretacji sygnałów z pozostałych kategorii:

- Average True Range (ATR) - mierzy typową skalę wahań ceny w danym oknie czasowym. Wysokie wartości ATR wskazują na okres podwyższonej zmienności, w którym duże ruchy cenowe są normą, niskie wartości wskazują na spokojny rynek, w którym nawet niewielki ruch może stanowić istotny sygnał. True Range dla pojedynczej świecy stanowi maksimum z trzech wartości, a ATR jest jego wygładzoną średnią z okresu n[23] przedstawioną we wzorze(25).

$$TR_t = MAX(H_t - L_t, |H_t - C_{t-1}|, |L_t - C_{t-1}|)$$

$$ATR_n = \frac{ATR_{n-1}(n-1) + TR_t}{n} \tag{25}$$

gdzie:

H, L, C – cena maksymalna,minimalna i zamknięcia świecy,

t – krok czasowy,

n – okres,

ATR jest wyrażony w jednostkach cenowych, przez co nie jest porównywalny względem instrumentów o rozbieżnych cenach, dlatego cechę wejściową wyrażono jako stosunek do ceny zamknięcia danego instrumentu zgodnie ze wzorem(26).

$$ATRTOCLOSE = \frac{ATR_t}{C_t} \tag{26}$$

gdzie:

C – cena zamknięcia świecy,

t – krok czasowy,

- Rolling Skewness - służy do pomiaru asymetrii rozkładu logarytmicznych zwrotów w oknie n. Sposób wyliczania tego wskaźnika wraz z zastosowaną korektą obciążenia przedstawia wzór (27). Dodatnia skośność wskazuje na częstsze występowanie znacznych ruchów w górę, ujemna na dominację gwałtownych spadków, natomiast wartości bliskie zeru oznaczają rozkład symetryczny[26].

$$m_2 = \frac{1}{n}\sum_{i=0}^{n-1}(r_{t-1} - \bar{r})^2, \qquad m_3 = \frac{1}{n}\sum_{i=0}^{n-1}(r_{t-1} - \bar{r})^3$$

$$SKEW_{(n)} = \frac{\sqrt{n(n-1)}}{n-2}\frac{m_3}{m_2^{3/2}} \tag{27}$$

gdzie:

r – logarytmiczny zwrot świecy,

$\bar{r}$ – średnia log-zwrotów w oknie n,

m_2 – drugi moment centralny log-zwrotów w oknie n,

m_3 – trzeci moment centralny log-zwrotów w oknie n,

n – okres,

t – krok czasowy,

Skośność jest wielkością bezwymiarową o wartościach naturalnie oscylujących wokół zera, dlatego sama w sobie stanowi cechę wejściową.

Kategorię wolumenu opisują cztery wskaźniki, których głównym zadaniem jest dostarczenie informacji o stanie bieżącej aktywności w celu oceny aktualnego zaangażowania podmiotów uczestniczących:

- Volume ROC - mierzy jednookresową zmianę wolumenu, wyrażoną wzorem(28) jako stosunek bieżącego wolumenu do poprzedniego. Gwałtowny wzrost wolumenu

może potwierdzać siłę bieżącego ruchu cenowego, natomiast spadek wolumenu przy kontynuacji ruchu cenowego może sygnalizować jego wyczerpanie[23].

$$VROC_t = \frac{V_t}{V_{t-1}} - 1 \tag{28}$$

gdzie:

V	– wolumen,
t	– krok czasowy,

Surowa wartość Volume ROC może sporadycznie przyjmować wartości skrajnie odbiegające od reszty obserwacji. Takie wartości dominowałyby statystyki normalizacyjne, kompresując typowe obserwacje w wąskim zakresie bliskim zera. W celu ograniczenia wpływu tych wartości ekstremalnych, zastosowano transformację logarytmiczną zachowującą znak zgodnie ze wzorem(29), ponieważ wskaźnik na nim bazuje.

$$VROCLOG_t = sign(VROC_t)\log(1 + |VROC_t|) \tag{29}$$

gdzie:

$sign$	– signum,
log	– logarytm naturalny,
t	– krok czasowy,

- PVOH (Percentage Volume Oscillator Histogram) - mierzy różnicę między linią PVO a jej linią sygnałową zgodnie ze wzorem(30), gdzie PVO wyraża procentową relację między szybką średnią kroczącą a wolną średnią kroczącą wolumenu. Rosnący histogram wskazuje na przyspieszanie aktywności wolumenowej, malejący na jej spowolnienie[27].

$$PVO_t = 100\frac{EMA_{n_1}(V_t) - EMA_{n_2}(V_t)}{EMA_{n_2}(V_t)}$$

$$PVOH_t = PVO_t - EMA_{n_3}(PVO_t) \tag{30}$$

gdzie:

V	– wolumen,
t	– krok czasowy,
n_1, n_2, n_3	– okresy,
EMA	– wykładnicza średnia krocząca,

PVO Histogram jest wielkością bezwymiarową i sam w sobie stanowi cechę wejściową.

- VWAP (Volume Weighted Average Price) - średnia cena ważona wolumenem obliczana w określonym oknie czasowym zgodnie ze wzorem (31). Reprezentuje cenę, po której przeciętnie dochodziło do transakcji. Cena powyżej wskaźnika oznacza, że większość uczestników rynku z danego okna jest na pozycji zyskownej, co sprzyja kontynuacji ruchu. Cena poniżej oznacza sytuację odwrotną i insynuuje presję sprzedażową[23].

$$TP_t = \frac{H_t + L_t + C_t}{3}$$

$$VWAP_n = \frac{\sum_{i=0}^{n-1} TP_{t-1} V_{t-1}}{\sum_{i=0}^{n-1} V_{t-1}} \tag{31}$$

gdzie:

H, L, C	– cena maksymalna, minimalna, zamknięcia,
V	– wolumen,
n	– okres,
t	– krok czasowy,

VWAP jest wyrażony w jednostkach cenowych, dlatego cechę wejściową wyrażono jako stosunek wskaźnika do ceny zamknięcia zgodnie ze wzorem(32).

$$CLOSETOVWAP = \frac{c_t}{VWAP_n} \tag{32}$$

gdzie:

C	– cena zamknięcia,
n	– okres,
t	– krok czasowy,

- AVWAP (Anchored VWAP) - funkcjonuje analogicznie do standardowego wskaźnika VWAP, jednak różni się sposobem agregacji danych. Zamiast wykorzystywać sumę kroczącą w stałym oknie czasowym, AVWAP resetuje proces akumulacji na początku każdej godziny, co definiuje wzór(33).

$$AVWAP = \frac{TP_t V_i}{\sum_{i=anchor}^{t} V_i} \tag{33}$$

gdzie:

$anchor$ – chwila rozpoczęcia sumowania,

V – wolumen,

AVWAP jest wyrażony w jednostkach cenowych, cechę wejściową modelu zdefiniowano jako stosunek ceny zamknięcia do wartości wskaźnika. Tę relację, skonstruowaną analogicznie do przypadku VWAP, opisuje wzór(34).

$$CLOSETOAVWAP = \frac{C_t}{AVWAP} \tag{34}$$

gdzie:

C – cena zamknięcia świecy,

t – krok czasowy,

Wskaźnikiem opisującym kategorię płynności i mikrostruktury jest wskaźnik Amihuda (ILLIQ). Mierzy on wpływ cenowy jednostki wolumenu, czyli jak dużą zmianę ceny powoduje dana wartość obrotu. Wysoka wartość AILLIQ oznacza niską płynność, w której niewielki wolumen powoduje duże zmiany ceny. Niska wartość oznacza płynność wysoką rynku, w której nawet duże zlecenia nie powodują istotnych ruchów cenowych. AILLIQ obliczany jest jako krocząca średnia stosunku bezwzględnego zwrotu do wartości obrotu w oknie n okresów zgodnie ze wzorem(35)[28].

$$ILLIQ_t = \frac{|r_t|}{C_t V_t}$$

$$AILLIQ_{(n)=} \frac{1}{n} \sum_{i=0}^{n-1} ILLIQ_{t-1} \tag{35}$$

gdzie:

r – stopa zwrotu,

C – cena zamknięcia,

V – wolumen,

t – krok czasowy,

n – okres,

Surowe wartości AILLIQ mogą sporadycznie przyjmować wartości skrajnie odbiegające od reszty obserwacji, co mogłoby negatywnie wpływać na stabilność modelu. W związku z tym ostateczną cechę wejściowa poddano transformacji logarytmicznej, którą opisuje wzór(36).

$$ALLIQLOG = \ln(AILLIQ) \tag{36}$$

gdzie:

ln – logarytm naturalny,

Z przedstawionych wskaźników technicznych wyekstraktowano łącznie 16 cech wiernie opisujących aktualną sytuację rynkową. Oprócz nich, wektor wejściowy uzupełniono także o dwie dodatkowe cechy, opisujące kształt świecy, tj. skalę odbicia ceny w danym interwale od lokalnego maksimum, wyrażaną wzorem(37) i lokalnego minimum, opisaną wzorem(38). Pozwoliło to na uchwycenie presji popytowej i podażowej występującej w danym interwale.

$$HIGHTOCLOSE = \frac{H - C}{C} \tag{37}$$

gdzie:

H – cena maksymalna,

C – cena zamknięcia,

$$LOWTOCLOSE = \frac{C - L}{C} \tag{38}$$

gdzie:

L – cena minimalna,

C – cena zamknięcia,

Dodatkowo wektor wejściowy rozszerzono o cechę opisującą logarytmiczną stopę zwrotu z poprzedniego kroku czasowego, wyrażaną wzorem(39) aby uwzględnić krótkookresową kierunkowość oraz dynamikę zmian ceny względem poprzedniego interwału.

$$LOGRETURN = \ln(\frac{C_t}{C_{t-1}}) \tag{39}$$

gdzie:

t – krok czasowy,

C – cena zamknięcia,

Właściwa kalkulacja wskaźników technicznych oraz cech wejściowych została przeprowadzona wyłącznie na świecach oznaczonych jako kompletne. Świece oznaczone jako brakujące w poprzednich podprocesach przetwarzania flagą MissingFlag, zostały wykluczone z obliczeń całkowicie. Co za tym idzie wskaźniki obliczono na ciągłej sekwencji kompletnych świec, co przy bardzo sporadycznych brakach w danych(< 0.1%) skutkuje nieznacznym przesunięciem efektywnego horyzontu czasowego okna więc rozwiązanie to uznano za dopuszczalne.

```
for (int i = 0; i < candles.Count; i++)
{
    if (candles[i] != null && candles[i].MissingFlag != true)
    {
       realCandles.Add(candles[i]);
     }
}
```

Obliczenia zrealizowano z wykorzystaniem tablic, co stanowi wydajniejsze rozwiązanie niż bezpośrednia iteracja po liście obiektów przekazanej do klasy realizującej funkcje obliczeniowe. Wynika to z mniejszego narzutu związanego z dostępem do danych, ponieważ tablice w przeciwieństwie do list obiektów przechowują elementy w spójnym, ciągłym obszarze pamięci i zapewniają bezpośredni dostęp indeksowany.

```
double[] closePrices = new double[candleCount];
...
for (int i = 0; i < candleCount; i++)
{
    closePrices[i] = realCandles[i].Close.Value;
    ...
}
```

Proces polegał na obliczeniu wszystkich wskaźników technicznych, przypisaniu wyników do odpowiadających im tablic, a następnie iteracyjnym przeniesieniu wartości do właściwych pól obiektów świecy.

```
double?[] sma10 = ComputeSma(closePrices, 10);
double?[] sma20 = ComputeSma(closePrices, 20);
double?[] rsi14 = ComputeRsi(closePrices, 14);
...

for (int i = 0; i < candleCount; i++)
{
    Candle candle = realCandles[i];

    candle.RSI = rsi14[i];
    ...
}
```

3.3. Definicja zmiennej celu oraz horyzontu predykcji

Drugim etapem modułu przetwarzania danych przedstawionym w załączniku 1 jest zdefiniowanie oraz kalkulacja odpowiednich etykiet, które stanowią zmienną celu dla modeli sekwencyjnych. Jest to kluczowy krok, który determinuje praktyczną użyteczność modeli oraz ich zdolność do generalizacji wiedzy.

Bezpośrednie prognozowanie wartości cenowych w następnym kroku czasowym przy użyciu regresji jest rozwiązaniem mało efektywnym ze względu na charakter danych oraz cel, jaki ma zostać osiągnięty. Z perspektywy finansowej istotna jest nie tyle przyszła wartość ceny w danym kroku czasowym, ile kierunek jej zmiany względem bieżącego momentu. Informacja ta umożliwia zajęcie zyskownej pozycji zgodnej z kierunkiem przyszłego ruchu cenowego.

Rynek finansowy nie porusza się jednak wyłącznie w kierunku wzrostowym bądź spadkowym. Przez znaczną część czasu ceny pozostają w fazie konsolidacji i oscylują w określonym przedziale. Analiza ograniczona do dwóch stanów nie odda w pełni rzeczywistej dynamiki notowań, a nawet może prowadzić do mylącej interpretacji sygnałów. W praktyce może się zdarzyć, że cena wzrośnie jedynie o kilka punktów procentowych względem badanego horyzontu, co poskutkuje nadaniem etykiety wzrostowej, podczas gdy z perspektywy finansowej zawarcie transakcji w takim scenariuszu miałoby znikomy sens. Z tego względu uzasadnione jest wyróżnienie dodatkowego stanu odpowiadającego ruchowi bocznemu, który pozwala odróżnić faktyczny trend od krótkotrwałych, mało istotnych wahań.

Najbardziej efektywną metodą klasyfikacji kierunku ruchu jest moda trzech barier[29] przedstawiona na rysunku 3.1. Polega ona na wyznaczeniu dwóch barier, wzrostowej (górna linia przerywana) oraz spadkowej (dolna linia przerywana), względem ceny zamknięcia bieżącej świecy (punkt niebieski) w określonym przedziale czasowym. Algorytm iteruje po kolejnych świecach w przód i sprawdza, która z barier zostanie osiągnięta jako pierwsza. Jeśli cena dotknie bariery górnej, świeca otrzymuje etykietę wzrostową (+1), jeśli dolnej, spadkową (−1). W przypadku przedstawionym na rysunku 3.1 cena w pierwszej kolejności przecina barierę spadkową (punkt czerwony), w związku z czym bieżąca świeca zostaje sklasyfikowana jako spadkowa, mimo że w dalszym horyzoncie czasowym cena ostatecznie przebija barierę wzrostową. Jeżeli w całym zadanym oknie czasowym żadna z barier nie zostanie osiągnięta, świeca klasyfikowana jest jako konsolidacyjna (0). Takie podejście pozwala na klasyfikację uwzględniającą rzeczywistą dynamikę rynku, w której etykieta odzwierciedla nie tylko kierunek, ale również istotność ruchu cenowego eliminując sygnały wynikające z nieznaczących wahań.

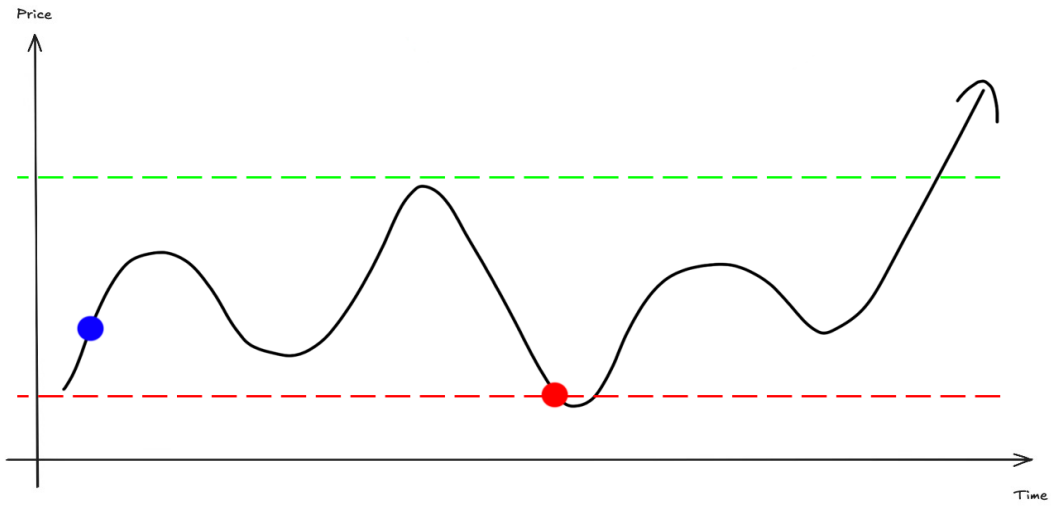

Rysunek 3.1. Metoda klasyfikacji kierunku trzech barier
Źródło: opracowanie własne

Kalkulacja etykiet polegała na obliczeniu progu zmienności w danym momencie rynkowym, do którego odnosi się klasyfikacja, z wykorzystaniem predefiniowanego mnożnika (1.5 dla interwału 5-minutowego, 1.3 dla 15-minutowego) oraz wartości atrtoclose obliczonej w poprzednim etapie preprocessingu. Na podstawie tego progu wyznaczone zostały właściwe bariery cenowe przy użyciu funkcji wykładniczej, co zapewnia ich symetryczność zapobiegając nierównemu rozkładu etykiet górnych względem dolnych.

```
barrierThreshold = 1.3 * candle.ATRTOCLOSE.Value;
upperBarrier = Close * Math.Exp(barrierThreshold);
lowerBarrier = Close * Math.Exp(-barrierThreshold);
```

Następnie wyznaczono horyzont predykcji, stanowiący de facto trzecią barierę (czasową). Jeżeli zmienność bieżącej świecy nie przekracza ustalonych progów wysokiej bądź niskiej zmienności horyzont wyznaczano za pomocą interpolacji liniowej pomiędzy tymi progami. Celem progów było wydłużenie okna dla okresów niskiej zmienności, oraz skróceniem dla okresów o zmienności wyższej. W przypadku pośrednim horyzont wyznaczano za pomocą interpolacji liniowej pomiędzy tymi wartościami.

```
interpolation = (atrPercent - lowVolThreshold) /
    (highVolThreshold - lowVolThreshold);
lookahead = maxLookahead + interpolation
    * (minLookahead - maxLookahead);
```

Na podstawie wyznaczonych barier algorytm iterował od bieżącej świecy po kolejne świece w przyszłości w obrębie obliczonego horyzontu przypisując etykietę w zależności od tego, która bariera została osiągnięta jako pierwsza.

3.4. Podział danych na zbiory treningowe, walidacyjne oraz testowe

Etapem zamykającym moduł przetwarzania danych dla modeli sekwencyjnych jest proces podziału przygotowanych próbek na odpowiednie podzbiory. Zastosowano klasyczny podział na trzy zbiory obejmujący:

- Zbiór treningowy – stanowiący główne źródło informacji, na podstawie którego sieć neuronowa uczy się rozpoznawać wzorce i zależności w danych. To na nim przeprowadzana jest propagacja wsteczna błędu oraz aktualizacja wag sieci,
- Zbiór walidacyjny – wykorzystywany w trakcie treningu do monitorowania zdolności generalizacyjnych modelu,
- Zbiór testowy – pełni rolę końcowej, niezależnej miary jakości modelu. Dane testowe nie wpływają bezpośrednio na zmianę wag w modelu predykcyjnym, co gwarantuje, że uzyskane na nich wyniki odzwierciedlają rzeczywistą zdolność modelu do generalizacji. Z tego względu na tym zbiorze również została przeprowadzona inferencja,

Przed przystąpieniem do właściwego podziału danych, rekordy zostały posortowane rosnąco według znacznika czasowego, co pozwoliło na zachowanie ścisłego porządku chronologicznego. Następnie z obu badanych interwałów (5-minutowego i 15-minutowego) usunięto pierwsze 30 rekordów. Rekordy zostały odrzucone ze względu na fakt, że większość wskaźników technicznych użytych w procesie inżynierii cech bazuje na średnich kroczących lub analizie okienkowej. Co za tym idzie, początkowe wartości tych wskaźników obliczane są na podstawie niepełnych danych, co czyni je niewiarygodnymi i mogłoby negatywnie wpłynąć na proces uczenia modeli.

```
var data5m = record.Data_5M.OrderBy(a =>
              a.Timestamp).Skip(30).ToList();

var data15m = record.Data_15M.OrderBy(a =>
              a.Timestamp).Skip(30).ToList();
```

Podział na zbiory został przeprowadzony poprzez wyznaczenie sztywnych granic czasowych. Obliczono je na podstawie zbioru danych o interwale 5-minutowym, stosując powszechnie przyjęte proporcje: 70% dla zbioru uczącego, 15% dla zbioru walidacyjnego oraz 15% dla zbioru testowego. Wyznaczone wartości stanowiły indeksy określające końcowe elementy poszczególnych podzbiorów.

```
trainidx = Clamp((int)(count * trainFrac), 1, count - 2);
validx = Clamp((int)(count * valFrac), trainidx + 1, count -1);
```

Następnie na podstawie tych indeksów, zidentyfikowano świece brzegowe. Do ich znaczników czasowych (timestamp) dodano 300 sekund (odpowiednik 5-minut w systemie unixowym). Zabieg ten, miał na celu ustawić granice przecięć na moment zamknięcia danej świecy, a nie jej otwarcia. Zapobiegając sytuacji, w której świeca wyższego interwału czasowego zaczyna się przed granicą, lecz zamyka się już po niej. Przykładowo, jeśli granica podziału wypadłaby na otwarciu świecy 5-minutowej o godzinie 15:30, to odpowiadająca jej świeca 15-minutowa, rozpoczynająca się o tej samej godzinie, zamykałaby się dopiero o 15:45. Tym samym informacja ze świeczki 15-minutowej, niosłaby w sobie informacje o dwóch świecach 5-minutowych, które znajdują się w innym zbiorze, stanowiąc wyciek danych.

```
long trainCut = candles[trainEndIdx].Timestamp + tfSeconds5m;
long valCut = candles[valEndIdx].Timestamp + tfSeconds5m;
```

Ostatnim krokiem było iteracyjne przejście po wszystkich świecach danego interwału. Dla każdej z nich obliczono czas zamknięcia, a następnie porównano z wcześniej wyznaczonymi granicami. Na tej podstawie świeca została przypisana do odpowiedniego zbioru. Każdy z tych zbiorów został następnie serializowany do formatu JSON i zapisany jako osobny plik, w celu dalszego przetwarzania.

```
foreach (var candle in ordered)
{
    long closeTs = candle.Timestamp + tfSeconds;

    if (closeTs <= cuts.TrainCutCloseTs)
    {
        train.Add(candle);
    }

    …
 }


File.WriteAllText(Path.Combine(folder, "training.txt"),
        JsonSerializer.Serialize(train, options));

File.WriteAllText(Path.Combine(folder, "validation.txt"),
        JsonSerializer.Serialize(validation, options));

File.WriteAllText(Path.Combine(folder, "test.txt"),
        JsonSerializer.Serialize(test, options));
```

4. Realizacja modeli predykcyjnych opartych o architekture LSTM

4.1. Architektura modeli sekwencyjnych

Architektura sekwencyjnych modeli predykcyjnych składa się z czterech głównych bloków przedstawionych na rysunku 4.1. Bloku embeddingu, bloku projekcyjnego, bloku sekwencyjnego opartego o warstwy LSTM oraz bloku klasyfikacyjnego. Każdy z bloków pełni odrębną rolę w procesie przetwarzania danych wejściowych a wspólnie tworzą potok transformujący surowy wektor cech opisany w rozdziale 3.2 w końcową predykcję kierunku ruchu cenowego.

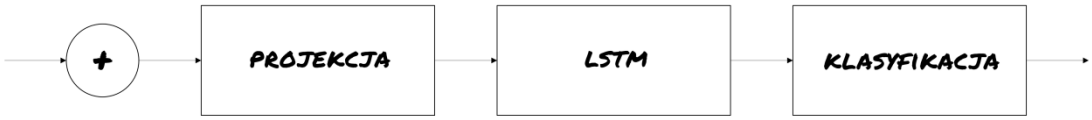

Rysunek 4.1. Architektura modelu sekwencyjnego
Źródło: Opracowanie własne

Blok embeddingu odpowiada za identyfikację spółki, której dane wejściowe są przetwarzane. Jak przedstawiono w rozdziale 3.1, model uczono na grupie kilku spółek jednocześnie, co wymagało mechanizmu pozwalającego na rozróżnienie źródła danych wejściowych. Zastosowano w tym celu warstwę osadzającą (ang. embedding layer), która przypisuje każdej spółce wektor o wymiarze n=16, uczony wspólnie z pozostałymi parametrami sieci w trakcie procesu treningu. Dzięki temu model może samodzielnie wykryć podobieństwa i różnice w zachowaniu cenowym poszczególnych spółek, bez konieczności ręcznego kodowania tych zależności.

```
self.ticker_emb = nn.Embedding(num_tickers, 16)
```

Wektor embeddingu rozszerzano wzdłuż wymiaru czasowego sekwencji i konkatenowano z wektorem cech wejściowych, tworząc łączny wektor wejściowy o wymiarze równym sumie wymiaru cech i wymiaru embeddingu.

Blok projekcyjny odpowiada za transformację skonkatenowanego wektora wejściowego do przestrzeni o wymiarze odpowiadającym rozmiarowi stanu ukrytego warstw LSTM w bloku sekwencyjnym. Projekcję zrealizowano jako połączenie warstwy liniowej z funkcją aktywacji GELU oraz warstwą dropout o współczynniku 0.2. Funkcję GELU wybrano zamiast powszechnie stosowanej ReLU ze względu na jej gładki charakter. W odróżnieniu od ReLU, która zeruje wszystkie wartości ujemne, GELU skaluje je w sposób ciągły, co sprzyja stabilności gradientów i ogranicza powstawanie martwych neuronów[30]. Zastosowanie projekcji, oprócz dostosowania wymiaru wektora wejściowego, miało również na celu odciążenie bloku sekwencyjnego z uczenia zależności

między cechami, pozwalając warstwom LSTM skoncentrować się wyłącznie na modelowaniu zależności czasowych w sekwencji.

```
self.input_projection = nn.Sequential(
            nn.Linear(total_input_dim, hidden_dim),
            nn.GELU(),
            nn.Dropout(dropout)
        )
```

Blok sekwencyjny stanowi rdzeń architektury i odpowiada za modelowanie zależności czasowych. Zrealizowano go jako stos dwóch warstw LSTM o rozmiarze wynoszącym 128. Zastosowanie dwóch warstw umożliwia budowanie hierarchicznych reprezentacji sekwencji. Pierwsza warstwa operuje na projekcjach wektora wejściowego, natomiast druga na reprezentacjach wytworzonych przez warstwę niższą, co pozwala na uchwycenie bardziej abstrakcyjnych zależności czasowych. Między warstwami zastosowano dropout o współczynniku 0.2 w celu ograniczenia nadmiernego dopasowania do danych treningowych.

```
self.lstm = nn.LSTM(
            input_size=hidden_dim,
            hidden_size=hidden_dim,
            num_layers=num_layers,
            dropout=dropout,
        )
```

Do dalszego przetwarzania wykorzystano wyłącznie stan ukryty ostatniego kroku czasowego sekwencji, który stanowi skompresowaną reprezentację całej historii obserwacji widzianej przez model.

Blok klasyfikacyjny odpowiada za wygenerowanie końcowej predykcji na podstawie reprezentacji wyprodukowanej przez blok sekwencyjny. Zrealizowano go jako dwuwarstwową sieć składającą się z dwóch prostych warstw liniowych oraz funkcji aktywacji GELU. Pierwsza warstwa redukowała wymiar ze 128 do 32, wymuszając ekstrakcję najbardziej istotnych cech. Druga warstwa generowała wektor logitów o wymiarze n=3 odpowiadający trzem klasom zdefiniowanym w rozdziale 3.3.

```
self.cls = nn.Sequential(
            nn.Linear(hidden_dim, 32),
            nn.GELU(),
            nn.Dropout(dropout),
            nn.Linear(32, num_classes),
        )
```

4.2. Przetwarzanie danych wejściowych oraz konfiguracja procesu uczenia

Wykorzystanie biblioteki PyTorch jako frameworka do budowy i trenowania modeli wiąże się z koniecznością przygotowania danych wejściowych w ściśle określony sposób. Mechanizm ładowania danych w PyTorchu oparty jest o klasę DataLoader, która automatyzuje grupowanie próbek w batche, miesza je oraz równolegle wczytuje. Klasa ta wymaga źródła danych w postaci obiektu dziedziczącego po klasie bazowej Dataset. Obiekt ten oczekuje implementacji dwóch metod: __len__ zwracającej liczbę próbek w zbiorze oraz __getitem__ zwracającej pojedynczą próbkę na podstawie jej indeksu.

Funkcjonalności te zrealizowano w ramach klasy MultiTickerDataset, której zadaniem było wczytanie plików tekstowych, zawierających dane w formacie JSON wygenerowane w module przetwarzania danych, przekształceniem ich w okienkowane sekwencje tensorów oraz normalizacja cech wejściowych.

Proces ładowania danych rozpoczynał się od iteracji po katalogach odpowiadającym poszczególnym spółkom w strukturze plików projektu. Dla każdej spółki wczytywano plik odpowiadający danemu podzbiorowi (treningowemu, walidacyjnemu lub testowemu), a następnie deserializowano jego zawartość z formatu JSON do listy obiektów reprezentujących świece.

Parsowanie pojedynczej świecy polegało na ekstrakcji wartości liczbowych dla każdej z kolumn cech zdefiniowanych w konfiguracji modelu. Dla każdego rekordu weryfikowano kompletność danych, sprawdzając, czy wszystkie wymagane pola są obecne, poprawnie konwertowalne do typu zmiennoprzecinkowego oraz wolne od wartości NaN. Rekordy niespełniające któregokolwiek z tych warunków wypełniano wektorami wartości NaN, co umożliwiało ich późniejsze wykluczenie na etapie budowania próbek bez naruszania ciągłości indeksowania w szeregu czasowym.

```
if row_ok:
   features.append(row)
else:
  features.append([float("nan")] * len(feature_columns))
```

Etykiety wyznaczone w rozdziale 3.3 metodą trzech barier przyjmowały wartości -1 (spadek), 0 (konsolidacja) oraz +1 (wzrost). Konwencja ta, choć naturalna, jest jednak niezgodna z wymaganiami biblioteki PyTorch, w której funkcja straty CrossEntropyLoss oczekuje etykiet z zakresu od zera. W związku z tym na etapie parsowania zastosowano przesunięcie wartości o jeden, przekształcając oryginalne etykiety na zakres $\{0, 1, 2\}$.

```
targets.append(int(raw_target) + 1)
```

Kluczowym etapem przygotowania danych było przekształcenie ciągłych szeregów czasowych w zbiór próbek okienkowych, zgodnych z oczekiwanym formatem. Dla każdej spółki iterowano po wszystkich możliwych pozycjach końcowych okna, weryfikując jednocześnie dwa warunki poprawności. Obecność prawidłowej etykiety klasyfikacyjnej na pozycji końcowej okna oraz brak jakichkolwiek wartości NaN w obrębie całego okna cech. Próbki niespełniające któregokolwiek z tych warunków były pomijane, co gwarantowało, że do procesu uczenia trafiają wyłącznie kompletne i wiarygodne sekwencje obserwacji.

```
for end_pos in range(self.window - 1, num_candles):
    target_val = targs[end_pos].item()
    window = feats[end_pos - self.window + 1 : end_pos + 1]
    self.samples.append((ticker_idx, end_pos))
```

To defensywne podejście było możliwe ze względu na niską częstotliwość próbek bezwartościowych. Dla okna o długości 30 świec pojedyncza brakująca wartość powodowałaby odrzucenie do 30 nakładających się próbek, co przy większej ilości pojedynczych brakujących rekordów skutkowałoby znaczącym zmniejszeniem zbioru.

Każda próbka reprezentowana była jako krotka identyfikatora spółki oraz indeksu pozycji końcowej okna. Właściwe wycinanie okna cech realizowane było dopiero w momencie pobrania próbki przez DataLoader w metodzie __getitem__, a nie na etapie budowania listy próbek. Pozwoliło to na przechowywanie danych w pamięci w postaci pełnych szeregów czasowych per ticker, zamiast powielania nakładających się fragmentów sekwencji. Takie podejście znacząco ograniczyło zużycie pamięci operacyjnej, ponieważ sąsiednie okna o długości n dzielą ze sobą $n-1$ elementów.

```
def __getitem__(self, idx):
    ticker_idx, end_pos = self.samples[idx]
    feats, targs, times = self.ticker_data[ticker_idx]
    window = feats[end_pos - self.window + 1 : end_pos + 1]
    target = int(targs[end_pos].item())
    return window, torch.tensor(target, dtype=torch.long),
ticker_idx, ...
```

Dane poddano normalizacji z-score, polegającej na wycentrowaniu każdej cechy względem jej średniej i przeskalowaniu przez odchylenie standardowe, co sprowadza rozkład wartości do rozkładu ze średnią zero i wariancją równą jeden[31]. Wybór ten podyktowany jest właściwościami procesu uczenia sieci neuronowych. Z-score centruje dane wokół zera, co sprzyja stabilności gradientów przy gładkich funkcjach aktywacji takich jak GELU zastosowana w bloku projekcyjnym.

Globalna normalizacja po wszystkich spółkach przesunęłaby średnią w kierunku dominującej spółki, kompresując lub rozciągając rozkłady pozostałych. Dlatego

normalizację przeprowadzono niezależnie dla każdej spółki, co pozwoliło zachować informacyjność cech niezależnie od różnic w poziomach cenowych i zmienności poszczególnych instrumentów.

```
stats_per_ticker[ticker_index] =
        {"mean": feature_mean, "std": feature_std}
```

Statystyki normalizacyjne, tj. średnią i odchylenie standardowe dla każdej cechy i każdej spółki, obliczono wyłącznie na zbiorze treningowym. Włączenie danych walidacyjnych i testowych do obliczeń spowodowałoby, że zarówno trening jak i ewaluacja operowałyby na cechach znormalizowanych z uwzględnieniem informacji niedostępnych w momencie podejmowania decyzji, zawyżając wyniki względem rzeczywistej skuteczności modelu.

W procesie uczenia do obliczania błędu predykcji zastosowano funkcję straty CrossEntropyLoss. Funkcja ta łączy w sobię operację softmax, przekształcającą surowe logity modelu w rozkład prawdopodobieństwa po klasach, z entropią krzyżową mierzącą rozbieżność między tym rozkładem a etykietą rzeczywistą. Wybór ten wynika bezpośrednio z formalizacji zadania opisanego w rozdziale 3.3 oraz faktu, iż rozkład etykiet w zbiorze treningowym nie jest równomierny. Klasa konsolidacyjna dominuje liczebnie, co jest naturalną konsekwencją charakterystyki rynków finansowych. Trening bez kompensacji prowadziłby do faworyzowania klasy dominującej kosztem klas kierunkowych, które z perspektywy finansowej są najistotniejsze. Problem ten rozwiązano poprzez parametryzację funkcji straty wagami klas. Błędna klasyfikacja próbki z klasy mniejszościowej generuje tym samym proporcjonalnie większą wartość straty, wymuszając na modelu poświęcenie większej uwagi wzorcom kierunkowym, zapobiegając faworyzowaniu najczęściej występującej klasy.

```
loss_fn = nn.CrossEntropyLoss(weight=class_weights)
```

Do aktualizacji wag modelu zastosowano optymalizator Adam, który utrzymuje adaptacyjne tempo uczenia dla każdego parametru na podstawie wykładniczo wygładzonych estymat pierwszego i drugiego momentu gradientów[32]. Wybór optymalizatora Adam podyktowany jest zróżnicowaną częstotliwością aktualizacji parametrów w architekturze. Warstwa embeddingu generuje rzadkie gradienty wyłącznie dla spółek obecnych w danym batchu. Wagi LSTM i warstwy projekcyjnej aktualizowane są w każdym kroku. Adam utrzymuje indywidualne estymatory pierwszego i drugiego momentu gradientu dla każdego parametru, co sprawia, że rzadko aktualizowane embeddingi otrzymują proporcjonalnie

większe efektywne tempo uczenia, a gęsto aktualizowane wagi rekurencyjne, mniejsze, zapobiegając niestabilności.

```
optimizer = torch.optim.Adam(model.parameters(),
        lr=LR, weight_decay=1e-5)
```

Adam dostosowuje tempo uczenia indywidualnie dla każdego parametru, jednak wszystkie te adaptacje odnoszą się do wspólnego globalnego tempa uczenia stanowiącego górną granicę skali aktualizacji. Wartość tę redukowano w trakcie treningu za pomocą funkcji ReduceLROnPlateau, która monitoruje stratę walidacyjną i zmniejsza globalne tempo uczenia o połowę w momencie, gdy strata przestaje się zmniejszać przez określoną liczbę kroków. Zabieg ten pozwala na stopniowe zawężanie kroków optymalizacji w miarę zbliżania się modelu do optymalnych wartości parametrów, zapobiegając oscylacjom wokół nich wynikającym ze zbyt dużego tempa uczenia.

```
lr_scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(
        optimizer, mode="min", factor=0.5, patience=2,
        verbose=True
    )
```

Właściwy proces uczenia przebiegał iteracyjnie w pętli epok. W każdej epoce model przetwarzał kompletny zbiór treningowy w batchach, wykonując dla każdego z nich obliczenie straty, propagację wsteczną oraz aktualizację wag. W celu stabilizacji procesu zastosowano obcinanie gradientów z progiem 1.0, zapobiegające gwałtownym aktualizacjom wag wynikającym ze zjawiska eksplodujących gradientów, na które architektury rekurencyjne są z definicji podatne.

```
nn.utils.clip_grad_norm_(model.parameters(),
                max_norm=max_grad_norm
        )
```

Po każdej epoce przeprowadzano ewaluację na zbiorze walidacyjnym. Jeżeli strata walidacyjna osiągnęła nowe minimum, stan modelu zapisywano. W przypadku braku poprawy przez daną liczbę epok, gdy model zaczynał uczyć się zbioru treningowego na pamięć trening przerywano przedwcześnie.

```
if val_loss < self.best_val_loss:
 torch.save(model.state_dict(), self.save_path)
else:
 self.epochs_without_improvement += 1
 if self.epochs_without_improvement >= self.patience:
  self.early_stop = True
```

4.3. Ocena jakości predykcji modeli sekwencyjnych

Ocenę skuteczności przeprowadzono niezależnie dla modelu operującego na interwale 5-minutowym (5m) oraz modelu operującego na interwale 15-minutowym (15m). Zbiory testowe na których opierała się ocena jakości wynosiły 103922 rekordy dla modelu 5m, oraz 34723 dla modelu 15m. Do oceny jakości modeli zastosowano zestaw trzech metryk:

- Raport klasyfikacji – zestawienie precision, recall oraz F1-score dla każdej z trzech klas predykcji, uzupełnione o średnią macro i średnią weighted biorącą pod uwage liczebność klas. Zastosowanie tej metryki wynika z konieczności oceny zachowania modelu per klasa. Globalna dokładność przy niezbalansowanym rozkładzie etykiet opisanym w rozdziale 3.3 mogłaby sugerować dobrą jakość modelu mimo całkowitego ignorowania klas mniejszościowych,
- Diagram kalibracji – ocenia zgodność między deklarowaną pewnością modelu a jego rzeczywistą dokładnością. Metrykę tę zastosowano jako sprawdzenie sensowności prawdopodobieństw wyjściowych z uwagi na ich dalsze wykorzystanie w module inferencji,
- Ważność cech – ilustruje wkład poszczególnych cech wejściowych w skuteczność predykcji. Metrykę tę zastosowano w celu analizy, na jakich cechach wejściowych model rzeczywiście opierał swoje decyzje.

Raport klasyfikacyjny modelu 5m przedstawiony w tabeli 4.1 wykazał dokładność (accuracy) równą 50,43%. Wynik ten stanowi istotną przewagę zarówno względem progu losowości klasyfikacji trójklasowej 33%, jak i względem naiwnego klasyfikatora przewidującego zawsze klasę dominującą, który osiągnąłby dokładność ~38,5%. Analiza metryk per klasa ujawnia jednak wyraźną nierównowagę poszczególnych klas. Dla klasy konsolidacyjnej uzyskano wysoką wartość f1 równą 0,676, co świadczy o tym, że model skutecznie rozpoznaje okresy konsolidacji cenowej. Klasa wzrostowa osiąga umiarkowany poziom f1 równy 0,499 przy recall równym 0,643, co uwidacznia, że model relatywnie chętnie typuje wzrosty, wykrywając ich większość kosztem obniżonej precyzji, generując przy tym pewną liczbę fałszywych sygnałów. Klasa spadkowa przy wskaźniku f1 równym 0,193 wypada bardzo słabo. Szczególnie niekorzystny jest recall wynoszący ~13,2%, co oznacza, że model identyfikuje poprawnie mniej niż co siódmą rzeczywistą obserwację spadkową. Taki profil błędów sugeruje, że model rzadko decyduje się na predykcję klasy

spadkowej mimo zastosowania ważonej funkcji straty, co może wynikać z niskiej separowalności sygnału spadkowego w zastosowanych cechach wejściowych.

Tabela 4.1. Wyniki raportu klasyfikacyjnego modelu 5-minutowego

	precision	recall	f1-score	support
spadek	0.3622	0.1319	0.1934	32278
konsolidacja	0.6592	0.6943	0.6763	40044
wzrost	0.4070	0.6438	0.4987	31600
accuracy			0.5043	103922
macro avg	0.4761	0.4900	0.4561	103922
weighted avg	0.4903	0.5043	0.4723	103922

Źródło: opracowanie własne

Raport klasyfikacyjny modelu 15m przedstawiony w tabeli 4.2 wykazał dokładność równą 52,78%. Podobnie jak w przypadku modelu 5m, wynik ten przewyższa zarówno próg losowości jak i naiwny klasyfikator przewidujący zawsze klasę dominującą (~39,8%). Analiza metryk per klasa ujawnia analogiczny wzorzec asymetrii, jednak z wyraźną poprawą we wszystkich klasach względem modelu 5m. Najbardziej znacząca zmiana względem modelu 5m dotyczy klasy spadkowej. F1 wzrosło z 0,193 do 0,288, a recall z ~13,2% do ~22,6%, co oznacza że model 15m lepiej radzi sobię z identyfikacją klasy spadkowej, identyfikując poprawnie niemal co czwartą rzeczywistą obserwację spadkową. Mimo że wynik ten nadal pozostaje najsłabszy spośród trzech klas, poprawa o niemal 10 punktów procentowych w recallu sugeruje, że wzorce poprzedzające ruch spadkowy są bardziej uchwytne na dłuższym interwale czasowym.

Tabela 4.2. Wyniki raportu klasyfikacyjnego modelu 15-minutowego

	precision	recall	f1-score	support
spadek	0.3971	0.2255	0.2877	10561
konsolidacja	0.6682	0.7626	0.7123	13821
wzrost	0.4173	0.5227	0.4641	10341
accuracy			0.5278	34723
macro avg	0.4942	0.5036	0.4880	34723
weighted avg	0.5110	0.5278	0.5092	34723

Źródło: opracowanie własne

Analiza kalibracji modelu 5m przedstawiona na rysunku 4.2 wykazała ECE równe 0,0224, świadczące o dobrej kalibracji modelu. Prawdopodobieństwa wyjściowe są wiarygodnym odzwierciedleniem rzeczywistej dokładności, co oznacza że mogą być

bezpośrednio wykorzystywane jako sygnał filtrujący w module inferencji. Słupki w przedziale pewności 0,3–0,5 oscylują wokół linii idealnej kalibracji, wskazując na brak znaczącego błędu w tym zakresie. Model ani nie przeszacowuje ani nie niedoszacowuje swojej pewności dla większości predykcji. Słupki w przedziale 0,6–0,9 nieznacznie wychodzą poza linię kalibracji idealnej, ukazując lekkie przeszacowanie pewności przy silniejszych sygnałach. Model deklaruje nieco wyższą pewność niż jego rzeczywista dokładność w tym zakresie. Histogram rozkładu pewności wskazuje, że zdecydowana większość próbek skupia się w przedziale 0,4–0,5, co jest jednocześnie świadectwem trudności zadania i właściwości modelu. Słabe i zaszumione sygnały na interwale 5-minutowym sprawiają, że model rzadko napotyka sekwencje na tyle jednoznaczne, by z wysoką pewnością wskazać jedną klasę. Niski rozkład pewności predykcji nie jest w tym przypadku wadą kalibracyjną, model nie "udaje" pewności której nie ma, lecz uczciwie odzwierciedla swój rzeczywisty poziom wiedzy o danych.

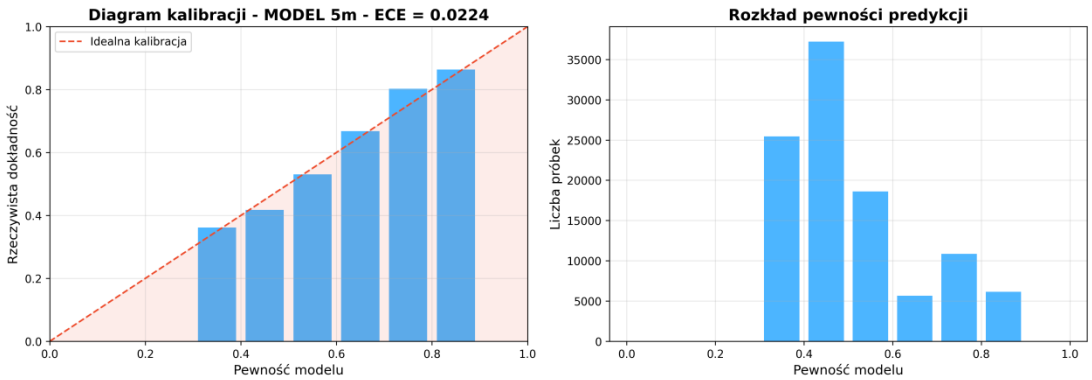

Rysunek 4.2. Diagram kalibracji modelu 5-minutowego
Źródło: opracowanie własne

Analiza kalibracji modelu 15m przedstawiona na rysunku 4.3 wykazała ECE równe 0,0143, co świadczy o lepszej kalibracji względem modelu 5m. Słupki w przedziale pewności 0,3–0,6 oscylują wokół linii idealnej, wskazując na brak przeszacowań i niedoszacowań w tym zakresie. Słupki w przedziale 0,6–0,8 nieznacznie przekraczają linię idealną, sygnalizując lekkie przeszacowanie pewności w tym przedziale. Ostatni słupek w przedziale 0,9–1,0 leży wyraźnie poniżej linii idealnej, jednak dotyczy zaledwie kilku obserwacji i nie ma istotnego wpływu na ogólną ocenę kalibracji. Histogram rozkładu pewności jest wyraźnie szerzej rozłożony niż w modelu 5m. Choć dominacja przedziału 0,4–0,5 jest nadal znacząca, widoczna jest istotnie większa liczba próbek klasyfikowanych z pewnością powyżej 0,5, co świadczy o tym, że model 15m częściej napotyka w danych sekwencje na tyle jednoznaczne, by z większą pewnością wskazać jedną klasę. Szerszy rozkład pewność predykcji jest rzeczywistym odzwierciedleniem siły sygnału,

co czyni prawdopodobieństwa modelu 15m bardziej wiarygodnym narzędziem filtrowania predykcji.

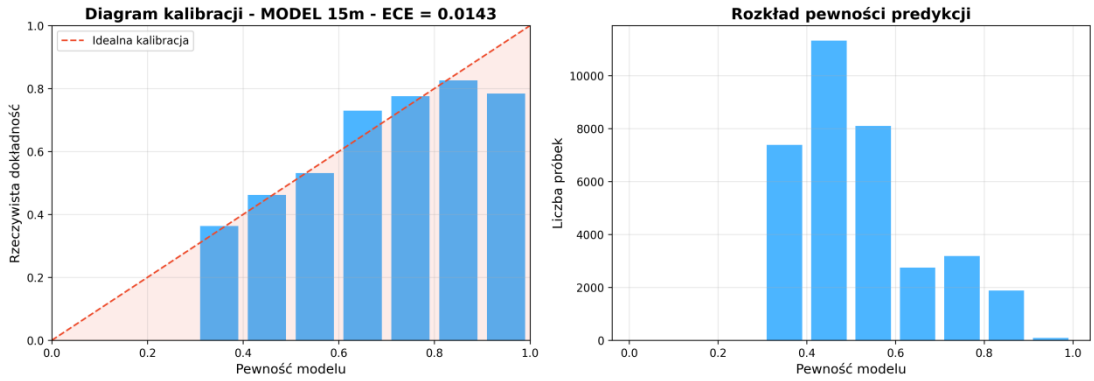

Rysunek 4.3. Diagram kalibracji modelu 15-minutowego
Źródło: opracowanie własne

Wykres analizy ważności cech modelu 5m przedstawiono na rysunku 4.4. Ujawnia on wyraźną dominację cech ATRTOCLOSE opisującej znormalizowaną skalę wahań oraz PVOH opisującą aktywność wolumenową. Dominacja tych dwóch cech sugeruje, że na interwale 5-minutowym model opiera decyzje przede wszystkim na intensywności ruchu i aktywności wolumenowej, co implikuje że to właśnie chwilowa zmienność i wolumen są głównymi nośnikami sygnału predykcyjnego na krótkich interwałach. Cechy strukturalne świecy takie jak LOWTOCLOSE i HIGHTOCLOSE oraz cechy trendu i momentum mają istotnie niższy wpływ na accuracy, co wskazuje że presja popytowo-podażowa i sygnały trendowe są na tym interwale zbyt słabe lub zbyt opóźnione by wnosić istotny wkład predykcyjny. Szczególnie wymowna jest ujemna ważność cech takich jak CloseVsSma50, Sma10VsSma20 czy SKEW. Ich permutacja poprawiała dokładność modelu, co oznacza że aktywnie szkodziły predykcji. Cechy oparte o relacje długookresowych średnich kroczących na interwale 5-minutowym można więc uznać za zbyt opóźnione względem dynamiki rynku by nieść wartość predykcyjną, stanowiąc jedynie źródło szumu zakłócającego generalizację modelu.

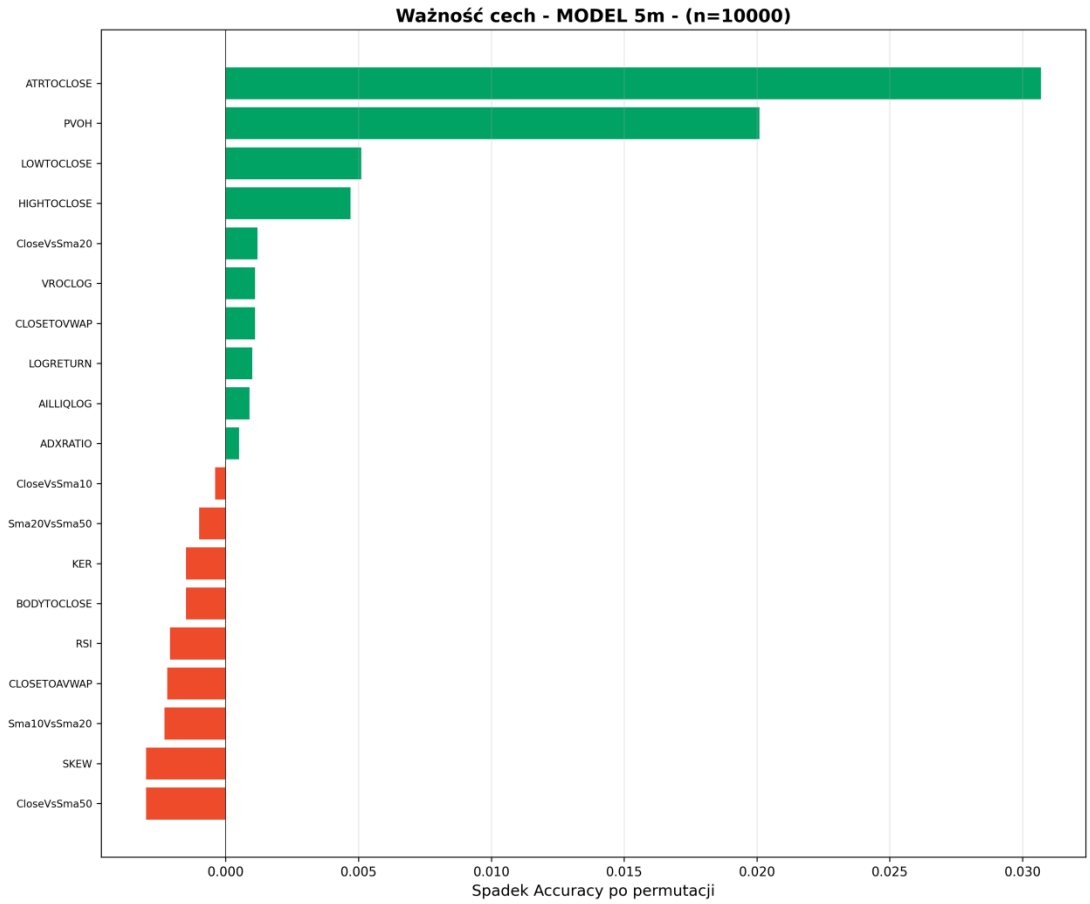

Rysunek 4.4. Analiza ważności cech modelu 5-minutowego
Źródło: opracowanie własne

Wykres analizy ważności cech modelu 15m przedstawiony na rysunku 4.5 prezentuje odmienną hierarchię względem modelu 5m. Na pierwszym miejscu uplasował się PVOH, jednak tym razem tuż za nim znalazły się cechy strukturalne świecy LOWTOCLOSE i HIGHTOCLOSE, opisujące presję podażową i popytową w danym interwale. Awans cech strukturalnych świecy na czołowe pozycje sugeruje, że na dłuższym interwale kształt pojedynczej świecy niesie więcej informacji predykcyjnej niż sama lokalna zmienność. 15-minutowa świeca zdążą uformować wyraźniejszą strukturę wewnętrzną odzwierciedlającą realną walkę popytu z podażą stanowiąc lepsze źródło informacji od niektórych wskaźników technicznych. Istotną różnicą względem modelu 5m jest również znacznie większa liczba cech pozytywnie wpływających na dokładność predykcji. Wskaźniki płynności (AILLIQLOG), momentum (VROCLOG, BODYTOCLOSE, MASSI, KER) oraz cechy trendu (CloseVsSma10, CloseVsSma50) wnoszą pozytywny wkład predykcyjny, co wskazuje że szerszy zestaw kategorii cech jest użyteczniejszy na interwale wyższym. Może to wynikać z faktu, że na interwale 5-minutowym ruchy cenowe rządzą się odmienną dynamiką, w której klasyczne wskaźniki techniczne opisujące trend, momentum czy płynność nie niosą istotnej wartości predykcyjnej. Na interwale 15-minutowym te same wskaźniki stają się użyteczne, co sugeruje że wyższy interwał lepiej odpowiada zjawiskom,

do pomiaru których zostały zaprojektowane. Cechy z ujemnym wpływem to RSI, Sma20VsSma50, ADXRATIO i Sma10VsSma20. Fakt że relacje średnich kroczących i wskaźnik względnej siły trendu szkodzą predykcji na obu interwałach stanowi przesłankę do usunięcia ich z wektora wejściowego w przyszłych iteracjach modelu.

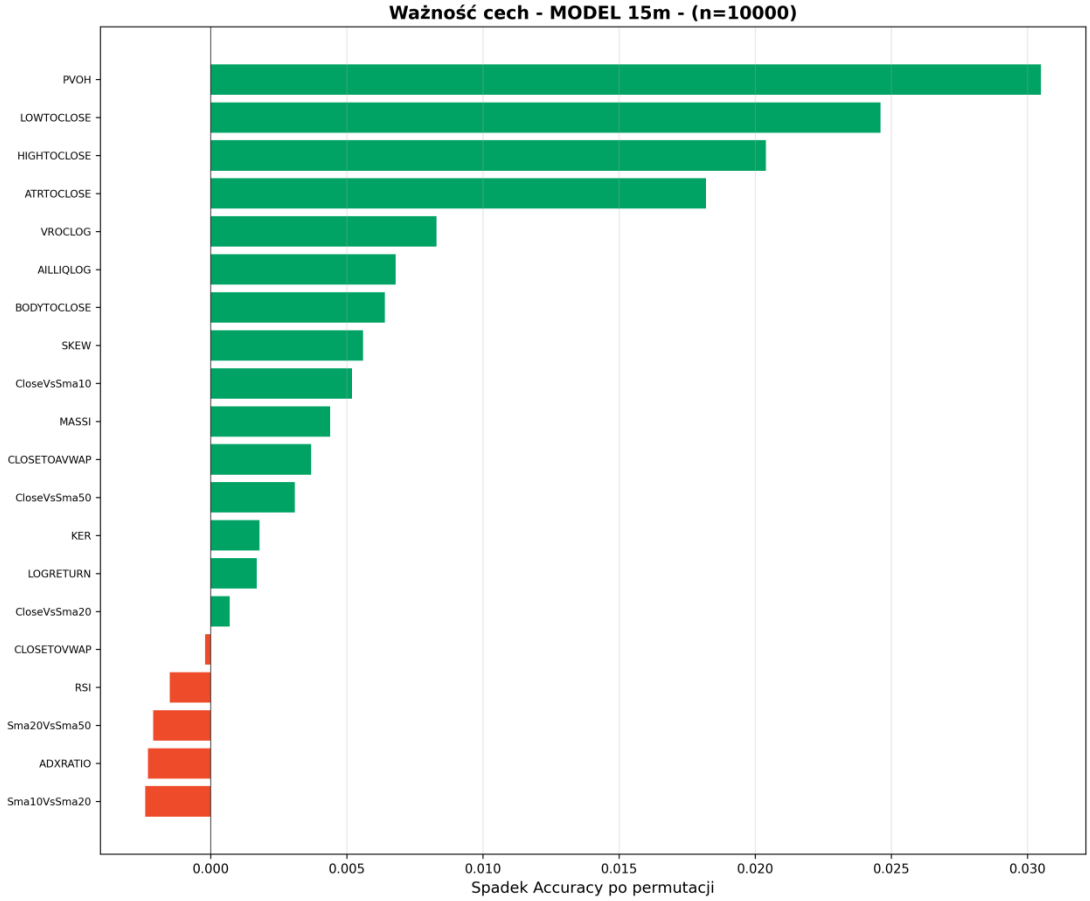

Rysunek 4.5. Analiza ważności cech modelu 15-minutowego
Źródło: opracowanie własne

Zestawiając wyniki obu modeli, model 15-minutowy uzyskał lepsze rezultaty we wszystkich analizowanych wymiarach. Wyższą dokładność, wyższe F1 dla każdej klasy, niższe ECE oraz bardziej równomierny i szerszy rozkład ważności cech. Wskazuje to na znaczącą trudność predykcji kierunku ruchu cenowego na krótkich interwałach czasowych, gdzie dominujący szum mikrostrukturalny skutecznie maskuje sygnały, na których opierają się klasyczne wskaźniki analizy technicznej. Dłuższy interwał naturalnie wygładza część tego szumu, pozwalając szerszemu zestawowi cech manifestować swoją wartość predykcyjną, co bezpośrednio przekłada się na lepsze wyniki.

5. Badanie skuteczności prognozowania modeli i analiza wyników

5.1. Metodologia inferencji

Celem modułu inferencyjnego jest weryfikacja, czy łączenie sygnałów predykcyjnych z modeli operujących na różnych interwałach czasowych przekłada się na wyższą skuteczność klasyfikacji kierunku ruchu cenowego względem modeli operujących na pojedynczym interwale. Dodatkowym przedmiotem weryfikacji jest wpływ integracji informacji tekstowych na jakość generowanych sygnałów transakcyjnych. Wyniki pozwalają przy tym ocenić praktyczną użyteczność wypracowanego podejścia z perspektywy tradingowej, poprzez symulację rzeczywistych decyzji inwestycyjnych na danych testowych.

Badanie skuteczności modeli przeprowadzono osobno dla każdej z siedmiu analizowanych spółek. Przyjęcie takiego podejścia wynika bezpośrednio z charakteru rzeczywistego problemu. Decyzja tradingowa jest zawsze podejmowana w odniesieniu do konkretnego instrumentu finansowego, na którym zawierana jest transakcja, więc testowanie modeli na danych łączonych wielu spółek mogłoby zaburzyć interpretacje rzeczywistej dokładności.

Dane, na których przeprowadzono inferencję, są danymi testowymi wydzielonymi na etapie przygotowania zbiorów. Nie brały one udziału w treningu ani walidacji modeli, co umożliwia rzetelną ocenę zdolności predykcyjnej.

Ważnym punktem inferencji jest analiza wiadomości i integracja ich wydźwięku z sygnałami modeli sekwencyjnych. Integracja została zrealizowana przy użyciu modelu FinBERT. Pretrenowanego modelu językowego bazującego na transformerowej architekturze BERT, dostosowanego do domeny finansowej poprzez dalszy trening na korpusie tekstów finansowych. Model wykorzystany w pracy pochodzi z repozytorium ProsusAI/finbert i został pobrany oraz zapisany lokalnie na potrzeby badania.

FinBERT został zaimplementowany z wykorzystaniem biblioteki transformers, która umożliwia załadowanie pretrenowanych modeli językowych i ich tokenizatorów bezpośrednio z lokalnego katalogu, oraz udostępnia interfejs do tokenizacji tekstu i uruchamiania modelu w trybie inferencji.

Sama analiza pojedynczego rekordu tekstowego polegała na tokenizacji tekstu do reprezentacji numerycznej akceptowanej przez model, przepuszczeniu jej przez sieć i przeliczeniu wynikowych logitów na rozkład prawdopodobieństwa funkcją softmax. Na podstawie wynikowych prawdopodobieństw obliczana była zmienna określana jako wskaźnik wydźwięku wiadomości, przyjęta w module inferencyjnym jako miara pozytywnego nastawienia rynkowego względem danej spółki. Wskaźnik ten przyjmuje wartości z przedziału [0, 1] gdzie wartość 0.5 stanowi wartość neutralną. Obliczany jest jako

suma iloczynów prawdopodobieństw klas i przypisanych im wag, gdzie klasie pozytywnej przypisano wagę 1,0, neutralnej 0,5, a negatywnej 0,0.

```
def analyze(self, text: str) -> dict:
            tokens = self.tokenizer(text,
            return_tensors="pt",truncation=True,
            max_length=512
        )

        probs = torch.softmax(
                self.model(**tokens).logits, dim=1
            )[0]

        score = probs[0].item() * 1.0 + probs[2].item() * 0.5
```

Proces inferencji przebiegał w sposób jednoprzebiegowy. Predykcje obu modeli LSTM generowane były raz dla całego zbioru testowego danego tickera, a sentyment obliczany był jednorazowo dla wszystkich wiadomości danej spółki przed właściwą inferencją. Dla każdej świecy wyznaczana była następnie średnia arytmetyczna wskaźników sentymentu ze wszystkich wiadomości opublikowanych w ciągu sześciu godzin poprzedzających moment jej zamknięcia.

Alternatywne podejście sekwencyjne, w którym modele uruchamiane byłyby osobno dla każdej świecy, a sentyment obliczany na bieżąco, prowadziłoby do znacznego narzutu obliczeniowego. Pojedynczy artykuł finansowy może wpadać w sześciogodzinne okno wielu kolejnych świec, co oznaczałoby wielokrotne przepuszczanie tego samego tekstu przez powolny model FinBERT. Przyjęte podejście wektorowe eliminuje ten problem. Każdy news analizowany jest dokładnie raz, predykcje LSTM generowane są dla całego zbioru w jednym przebiegu, a wszystkie dalsze operacje w module strategii sprowadzają się do działań na gotowych tablicach, bez dodatkowych wywołań modeli.

Ze względu na niską skuteczność modeli w identyfikacji klasy spadkowej, moduł inferencyjny został zrealizowany jako dwuklasowy problem decyzyjny, operujący wyłącznie na sygnałach wzrostowych. Świadome uznanie ograniczeń modeli i zawężenie przestrzeni decyzyjnej do obszaru, w którym generuje on wiarygodne sygnały, jest bardziej wartościowe niż forsowanie predykcji klasy, której model nie jest w stanie skutecznie rozpoznać. Pozwala to na rzetelniejszą ocenę rzeczywistej zdolności predykcyjnej w testach, gdzie wyniki nie są zaburzane przez losowe sygnały krótkie, a wnioski dotyczące skuteczności strategii odnoszą się do tej części przestrzeni predykcyjnej, w której modele faktycznie wnoszą wartość informacyjną.

5.2. Strategie łączenia modeli predykcyjnych

Łączenie modeli predykcyjnych opiera się na surowym prawdopodobieństwie zwracanym przez dany model. Stanowi ono podstawę logiki decyzyjnej utworzonych strategii. Sygnał wejścia generowany jest gdy spełnione są jednocześnie dwa podstawowe warunki bazowe, z których korzystają wszystkie strategie decyzyjne.

Podstawą klasyfikacji sygnału jako wystarczającego względem zajęcia pozycji długiej jest spełnienie warunku kierunkowego przedstawionego jako(40), którego celem jest zapewnienie że model przypisuje klasie wzrostowej wystarczająco wysokie prawdopodobieństwo, stanowiące minimalny poziom pewności wymagany do podjęcia decyzji inwestycyjnej.

$$p_{up} > TRESH \tag{40}$$

gdzie:

p_{up} – prawdopodobieństwo klasy wzrostowej,

$TRESH$ – próg kierunkowy

Drugim warunkiem, klasyfikującym sygnał jako wartościowy jest dźwignia bezpieczeństwa predykcji przedstawiona jako(41). Jej uzasadnienie wynika ze zgodności modeli predykcyjnych co do jakości rozpoznawania sygnałów konsolidacyjnych. Jeśli model przypisuje wysokie prawdopodobieństwo klasie konsolidacyjnej, należy mu zaufać i zrezygnować z wejścia w pozycję. Wniosek ten wynika bezpośrednio z raportów klasyfikacyjnych przedstawionych w rozdziale 4.3, gdzie f1 klasy konsolidacyjnej osiągnęły najwyższe wartości spośród wszystkich klas dla obu modeli.

$$p_{flat} < TRESH \tag{41}$$

gdzie:

p_{flat} – prawdopodobieństwo klasy konsolidacyjnej,

$TRESH$ – próg dźwigni bezpieczeństwa

Do badania przygotowano jedenaście wariantów strategii decyzyjnych, obejmujących modele operujące na pojedynczym interwale czasowym jako punkt odniesienia, warianty łączące sygnały obu modeli oraz rozszerzenia modeli jednostkowych wzbogacone o informację sentymentową. Taki dobór próby umożliwił weryfikację wpływu poszczególnych elementów na jakość predykcji. Zestawienie wszystkich wariantów wraz z ich źródłami sygnału przedstawiono w tabeli 5.1.

Tabela 5.1. Zestawienie wariantów strategii decyzyjnych wraz ze źródłami sygnału

Strategia	Model 5m	Model 15m	NLP
baseline_5m	TAK	NIE	NIE
baseline_15m	NIE	TAK	NIE
agreement	TAK	TAK	NIE
softvote	TAK	TAK	NIE
gate_15m_exec_5m	TAK	TAK	NIE
nlp_veto_5m	TAK	NIE	TAK
nlp_veto_15m	NIE	TAK	TAK
nlp_boost_5m	TAK	NIE	TAK
nlp_boost_15m	NIE	TAK	TAK
nlp_combined_5m	TAK	NIE	TAK
nlp_combined_15m	NIE	TAK	TAK

Źródło: opracowanie własne

Podstawowymi strategiami pełniącymi rolę odnośników są baseline_5m i baseline_15m, generujące sygnał wyłącznie na podstawie spełnienia warunków bazowych przez dany model sekwencyjny. Reprezentują klasyczne podejście jednointerwałowe, względem którego oceniana jest wartość dodana łączenia modeli.

Strategia agreement łączy sygnały obu modeli w sposób symetryczny, wymagając jednoczesnego spełnienia warunków bazowych przez oba interwały. Reprezentuje naiwne podejście do fuzji modeli. Jej celem jest weryfikacja czy sama zgodność kierunkowa dwóch modeli operujących na różnych interwałach przekłada się na wyższą jakość sygnałów kosztem ich liczby.

Strategia softvote stanowi najprostszy wariant łączenia sygnałów obu modeli. Prawdopodobieństwa klasy wzrostowej oraz konsolidacyjnej uśredniane są arytmetycznie między modelami, a następnie poddawane standardowej weryfikacji warunków bazowych. Celem strategii jest weryfikacja czy proste uśrednienie rozkładów prawdopodobieństwa dwóch modeli operujących na różnych interwałach, bez wymogu ich zgodności kierunkowej, przekłada się na lepszą jakość sygnałów niż każdy z modeli osobno.

Strategią hierarchiczną wprowadzającą podział ról między modelami jest gate_15m_exec_5m. Model 15m, ze względu na swoją szerszą perspektywę oraz lepszą kalibrację pełni rolę filtru reżimu rynkowego blokując sygnały które nie spełniają wymogu dźwigni bezpieczeństwa. Model 5m, z uwagi na krótszy horyzont czasowy i większą wrażliwość na bieżącą dynamikę rynku, pełni rolę egzekutora, to jego ocena kierunkowa stanowi właściwy sygnał wejścia w pozycję. Celem tej strategii jest weryfikacja czy dodatkowe potwierdzenie braku konsolidacji z perspektywy dłuższego interwału redukuje

liczbę fałszywych sygnałów modelu 5m, przekładając się na wyższą jakość kosztem mniejszego pokrycia.

Strategie veto z mechanizmem nlp działają pasywnie jako filtr negatywny. Nie generują nowych sygnałów, lecz eliminują te ocenione jako sprzeczne z aktualnym nastrojem rynku. Jeśli wskaźnik wydźwięku spada poniżej ustawionego progu, sygnały wejściowe są odrzucane mimo spełnienia warunków bazowych. Celem tych strategii jest weryfikacja czy eliminacja sygnałów generowanych w warunkach negatywnego sentymentu rynkowego poprawia skuteczność względem wariantów bez komponentu tekstowego.

Strategie boost z mechanizmem nlp działają odwrotnie do strategii veto. Zamiast blokować sygnały, obniżają progi wejścia gdy próg sentymentu jest wystarczająco pozytywny, dopuszczając sygnały które bez wsparcia sentymentu zostałyby odrzucone. Celem jest weryfikacja czy sentyment niesie dodatkową wartość predykcyjną pozwalającą skutecznie obniżyć poprzeczkę wejścia dla modeli sekwencyjnych zwiększając ilość wejść przy jednoczesnym braku pogorszenia jakości sygnałów.

Strategie combined z mechanizmem nlp stanowią proste rozszerzenie modeli sekwencyjnych o sentyment. Sygnał jest dopuszczony po spełnieniu warunków bazowych, bądź gdy wartość sentymentu pozytywnego przekracza ustalony próg. Celem strategi jest znaczące zwiększenie próby oraz weryfikacja czy pozytywny sentyment o wystarczającej sile ma samodzielną wartość predykcyjną niezależnie od wskazań modelu cenowego.

Wszystkie strategie operują na tym samym zestawie globalnie zdefiniowanych progów decyzyjnych, co zapewnia pełną porównywalność wyników. Różnice w skuteczności między wariantami wynikają wyłącznie z mechanizmu łączenia sygnałów, nie z odmiennej kalibracji progów.

Wartości podstawowych progów bazowych zostały dobrane z uwzględnieniem rozkładu pewności predykcji obu modeli przedstawionego w rozdziale 4. Jak wynika z diagramów kalibracji, zdecydowana większość próbek skupia się w przedziale pewności 0,4–0,5 co implikuje to, że model rzadko jest bardzo zdecydowany. Ustawienie progów na wyższym poziomie odcięłoby zbyt dużą część sygnałów, uniemożliwiając statystycznie miarodajną ocenę strategii. Przyjęte wartości przedstawione w tabeli 5.2 stanowią zatem kompromis między selektywnością sygnałów a wystarczającą ich liczbą do rzetelnej ewaluacji.

Tabela 5.2. Wartości podstawowych progów decyzyjnych strategii

Próg kierunkowy	Próg dźwigni bezpieczeństwa
0,45	0,40

Źródło: opracowanie własne

Progi wartości sentymentowych przedstawione w tabeli 5.3, na których bazują strategie zawierające komponent przetwarzania języka naturalnego, zostały ustalone symetrycznie względem punktu neutralnego wskaźnika wydźwięku wiadomości wynoszącego 0,5. Odchylenie o 0,1 wystarczy do klasyfikacji sentymentu jako negatywny bądź pozytywny. W przypadku progu dla strategi combined z powodu odmiennej roli jaką pełni, próg został zwiększony o drugą wielokrotność odchylenia do poziomu 0,70. Sentyment nie filtruje tu sygnału modelu cenowego, lecz samodzielnie go zastępuje, co wymaga wyższego poziomu pewności co do kierunku nastroju rynkowego.

Tabela 5.3. Wartości progów sentymentowych

Negatywny(veto)	Pozytywny(boost)	Combined
0,4	0,6	0,7

Źródło: opracowanie własne

5.3. Prezentacja oraz intepretacja uzyskanych rezultatów

Predykcje modelu 5-minutowego połączono z odpowiadającymi im predykcjami modelu 15-minutowego poprzez wyrównanie po znacznikach czasowych zamknięcia świec, tworząc wspólną ramkę danych umożliwiającą jednoczesną inferencję obu modeli dla każdego wspólnego punktu czasowego. Oznacza to, że inferencja wszystkich strategii odbywała się z częstotliwością 15-minutową. Do oceny jakości strategii zastosowano zestaw trzech metryk:

- Współczynnik skuteczności – ze względu na dwuklasowy charakter inferencji zastosowano prosty wskaźnik informujący o odsetku pozycji zgodnych z rzeczywistym kierunkiem ruchu cenowego spośród wszystkich wygenerowanych sygnałów.
- Istotność statystyczna – jednostronny test dwumianowy weryfikujący czy obserwowana skuteczność strategii jest wynikiem rzeczywistej zdolności predykcyjnej modelu, czy przypadku. Hipoteza zerowa zakłada, że prawdopodobieństwo trafnej predykcji wynosi 50%.
- Krzywe kapitału PnL – symulacja rzeczywistego tradingu na wygenerowanych sygnałach, obrazująca skumulowany wynik finansowy strategii w czasie.

Wykresy skuteczności strategii przedstawione na rysunkach 5.1–5.7 ujawniają wyraźne zróżnicowanie zdolności predykcyjnej modeli w zależności od danego instrumentu. Na spółkach AAPL i GOOGL 21 z 22 przygotowanych strategii osiągnęły poziom skuteczności wyższy niż granica progu losowości problemu dwuklasowego wynosząca 50%.

Spółki takie jak NVDA czy META prezentują sytuację odwrotną, gdzie wszystkie strategie klasyfikują się znacząco poniżej progu losowości. MSFT prezentuje obraz zbliżony do META i NVDA, oscylując w bardzo wąskim przedziale 49,1–50,4% bez wyraźnej przewagi jakiejkolwiek strategii. Na AMZN widoczna jest wyraźna asymetria między interwałami, gdzie strategie oparte o model 5m konsekwentnie utrzymują się powyżej progu losowości osiągając 50–51,7%, podczas gdy wszystkie strategie oparte o model 15m plasują się poniżej niego, wskazując że na tym instrumencie użyteczny sygnał predykcyjny istnieje wyłącznie na krótszym interwale. TSLA stanowi najbardziej skrajny i zarazem najciekawszy przypadek w całym badaniu, gdzie strategie oparte o model 15m osiągają skuteczność w przedziale 58–65%, przy czym baseline_15m samodzielnie uzyskuje wynik 65,2%, podczas gdy strategie oparte o model 5m oscylują wokół progu losowości lub poniżej. Tak radykalna rozbieżność między interwałami na tym instrumencie sugeruje że wzorce poprzedzające ruch kierunkowy na TSLA manifestują się wyłącznie na horyzoncie 15-minutowym, pozostając niewidoczne dla modelu operującego na krótszym interwale.

Strategie łączące modele sekwencyjne w sposób naiwny poprzez wymóg zgodności obu interwałów w przypadku strategii agreement oraz przez proste uśrednienie rozkładów prawdopodobieństwa w przypadku softvote wykazują spójne zachowanie pomiędzy wszystkimi analizowanymi spółkami, jednak każda z odmiennego powodu. Softvote z definicji uśrednia sygnały obu modeli przez co jego wynik zawsze dąży do środka między nimi, nie będąc w stanie przekroczyć lepszego z modeli bazowych. Agreement natomiast jako filtr przecięcia redukuje pokrycie do sygnałów akceptowanych przez oba modele jednocześnie, co przy rozbieżnych modelach eliminuje wartościowe sygnały silniejszego z nich. Jedynym scenariuszem w którym obie strategie mogą przynieść marginalną korzyść jest sytuacja gdy oba modele bazowe są porównywalnie skuteczne i osiągają zbliżone wyniki. Przykładem takiej sytuacji jest NVDA gdzie modele bazowe plasują się na podobnym poziomie ~47% a strategie łączenia uzyskały od nich nieznacznie lepsze rezultaty. Nie zmienia to jednak ogólnej oceny że w przypadku wyraźnej asymetrii między modelami bazowymi, która jest regułą a nie wyjątkiem w przeprowadzonym badaniu, obie strategie łączenia naiwnego nie stanowią efektywnej metody fuzji sygnałów predykcyjnych i nie wnoszą wartości dodanej względem samodzielnego zastosowania lepszego z modeli bazowych.

Strategia łączenia hierarchicznego gate_15m_exec_5m, której celem było wykorzystanie szerszej perspektywy rynkowej modelu 15m jako filtru reżimu z precyzją sygnału wykonawczego modelu 5m, również nie przyniosła wartości dodanej na żadnej z analizowanych spółek, plasując się konsekwentnie na poziomach zbliżonych lub nieznacznie niższych od baseline_5m. Wskazuje to że dodatkowa informacja o trendzie z perspektywy dłuższego interwału nie stanowi użytecznego filtru jakości dla sygnałów

modelu 5m, a jej włączenie w najlepszym przypadku pozostaje neutralne względem modelu pojedynczego.

Strategie boost zawierające komponent sentymentu skutecznie zwiększyły pokrycie względem swoich bazowych odpowiedników na każdej z analizowanych spółek, oscylując przy tym na zbliżonym poziomie skuteczności. Na spółkach takich jak AAPL, GOOGL i MSFT strategia nlp_boost_5m dodatkowo poprawiła skuteczność osiągając najwyższe wartości spośród wszystkich jedenastu strategii dla tych instrumentów, co sugeruje że informacja sentymentowa dotycząca tych spółek niesie realną wartość predykcyjną i wykazuje korelację z krótkoterminowym kierunkiem ruchu cenowego. Na pozostałych instrumentach wzrost pokrycia nie przełożył się na poprawę skuteczności, nie powodując jednak znaczących jej spadków, co czyni wartość dodaną sentymentu potencjalnie wartą dalszej eksploracji i optymalizacji w kontekście doboru progów oraz sposobu integracji z modelem sekwencyjnym.

Strategie z mechanizmem veto zachowują się znacznie mniej spójnie względem strategii z mechanizmem boost i nie prezentują jednoznacznego wzorca wartości dodanej. Zgodnie z założeniem mechanizmu, każdy wariant veto konsekwentnie redukuje pokrycie względem swojego modelu bazowego poprzez eliminację sygnałów generowanych w warunkach negatywnego sentymentu. Wpływ tej eliminacji na skuteczność jest jednak silnie zależny od instrumentu i poprawia skuteczność tylko w nielicznych przypadkach. Ogólna ocena mechanizmu veto jest zatem mniej korzystna niż boost, redukuje pokrycie w sposób gwarantowany, natomiast poprawa skuteczności jest okazjonalna i nieprzewidywalna. Może to sugerować, że negatywny sentyment nie jest symetrycznym odpowiednikiem pozytywnego w kontekście predykcji kierunku ruchu cenowego. Zjawisko to znajduje częściowe oparcie w literaturze dotyczącej asymetrycznej reakcji rynku na szoki informacyjne. Badania wskazują że pozytywne szoki informacyjne generują silniejszą i bardziej trwałą odpowiedź niż ich negatywne odpowiedniki[33]. W kontekście niniejszego badania sugeruje to, że sygnały generowane przy pozytywnym sentymencie mają znacznie wyższą zdolność prognozowania trendów. Z kolei negatywny nastrój jest dużo słabszym predykatorem spadków, przez co mechanizm veto odrzuca zbyt wiele potencjalnie zyskownych zagrań. Ukazuje to fundamentalną asymetrię w tym, jak rynek dyskontuje informacje tekstowe.

Strategie combined, zwiększając pokrycie ponad poziom modelu bazowego, z definicji zawierają transakcje wygenerowane wyłącznie na podstawie silnego pozytywnego sentymentu bez jakiegokolwiek potwierdzenia ze strony modelu cenowego. Fakt iż skuteczność tych dodatkowych sygnałów nie obniżyła istotnie ogólnego wyniku strategii, a na niektórych instrumentach nawet go poprawiła, stanowi dodatkowe potwierdzenie wspomnianej asymetrii i wartości jaką niesie sentyment pozytywny.

Pozytywny sentyment częściej współwystępuje z kontynuacją trendu wzrostowego, za którym strategia combined po prostu podąża, co jest spójne z obserwacją, że pozytywne szoki informacyjne generują silniejszą i bardziej trwałą odpowiedź niż ich negatywne odpowiedniki. Jest to bezpośrednim argumentem przemawiającym za dalszą eksploracją mechanizmów integracji komponentu NLP z modelami predykcji kierunkowej w celu pełniejszego wykorzystania predykcyjnego potencjału pozytywnego sentymentu.

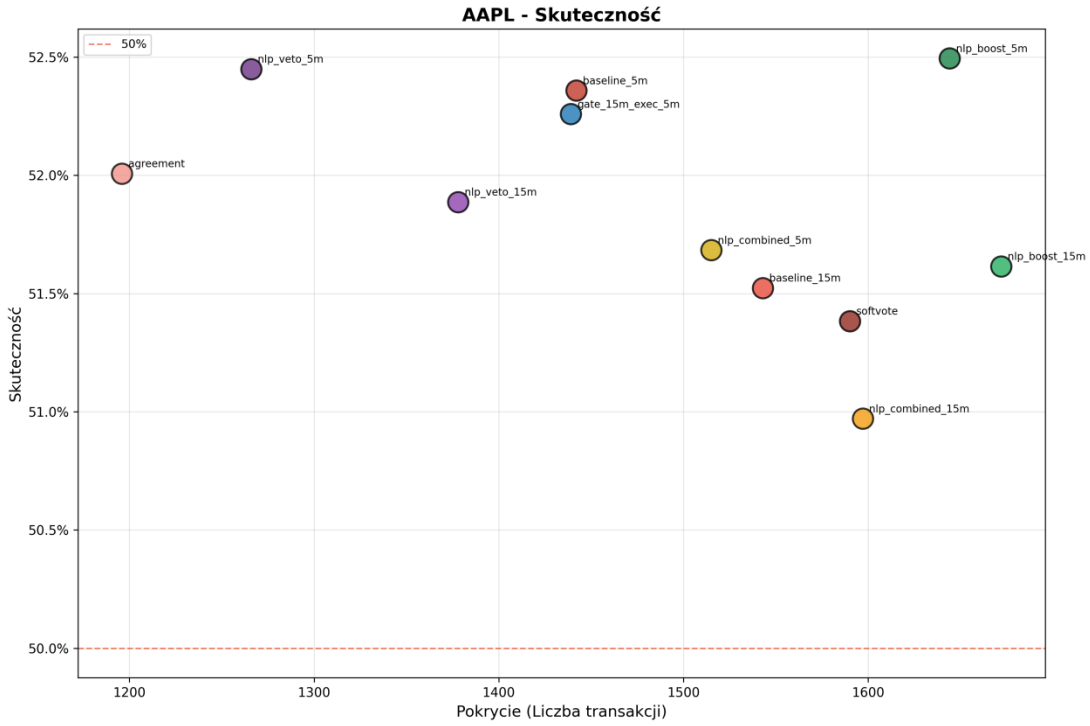

Rysunek 5.1. Wykres skuteczności strategii dla spółki AAPL
Źródło: opracowanie własne

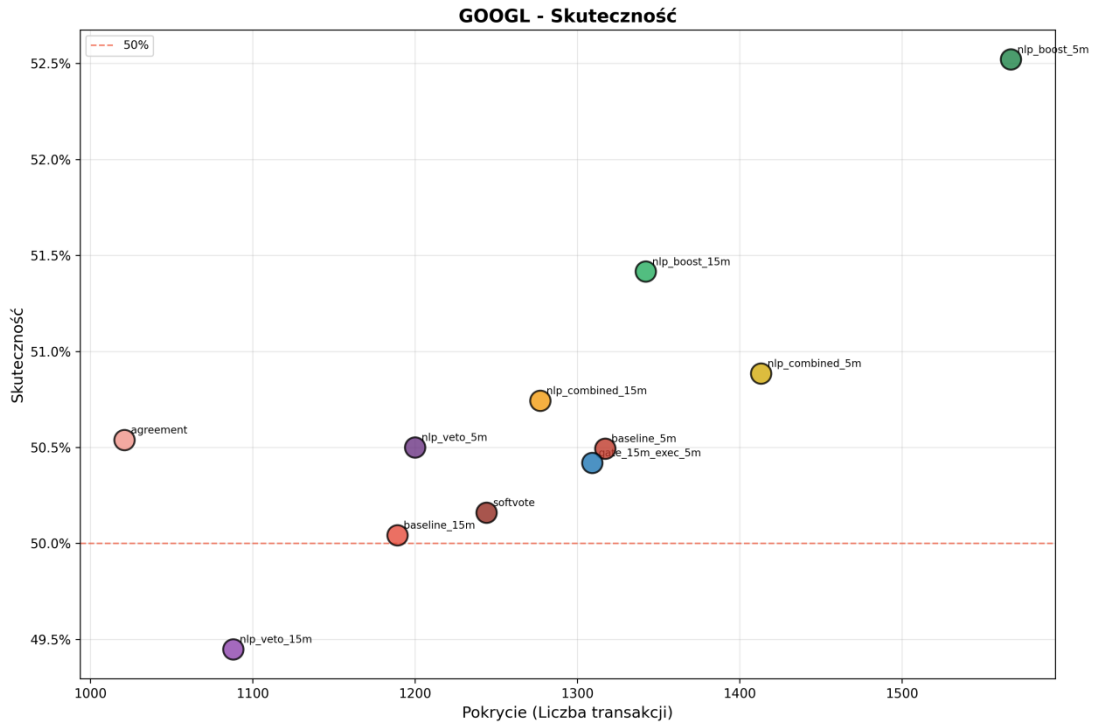

Rysunek 5.2. Wykres skuteczności strategii dla spółki GOOGL
Źródło: opracowanie własne

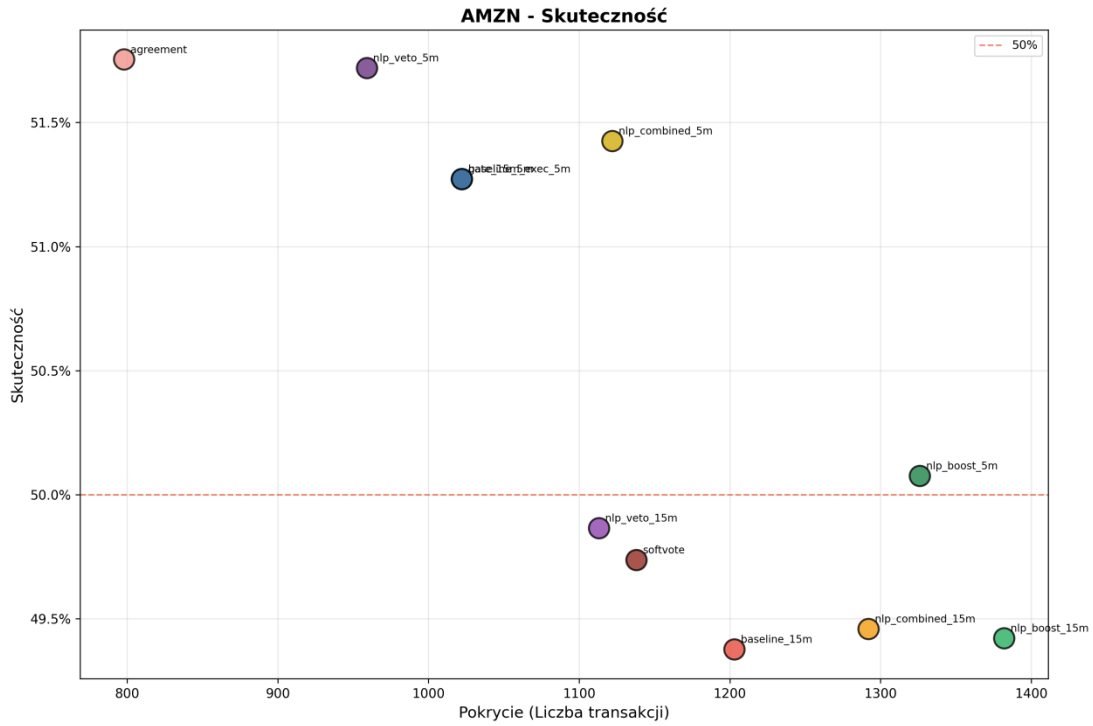

Rysunek 5.3. Wykres skuteczności strategii dla spółki AMZN
Źródło: opracowanie własne

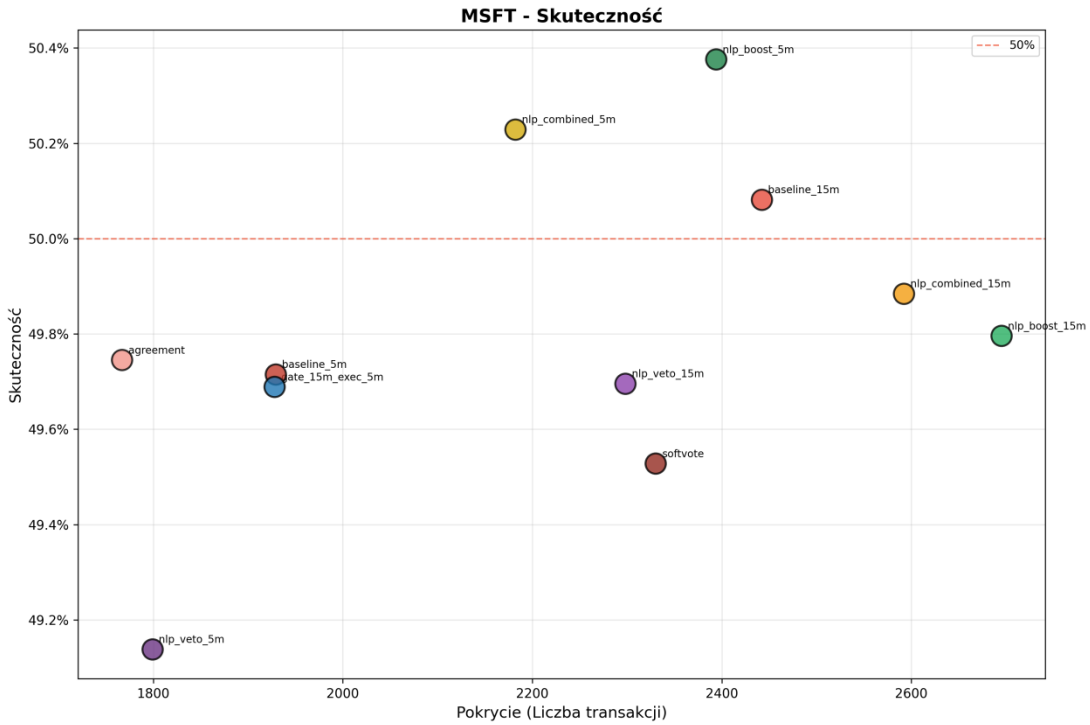

Rysunek 5.4. Wykres skuteczności strategii dla spółki MSFT
Źródło: opracowanie własne

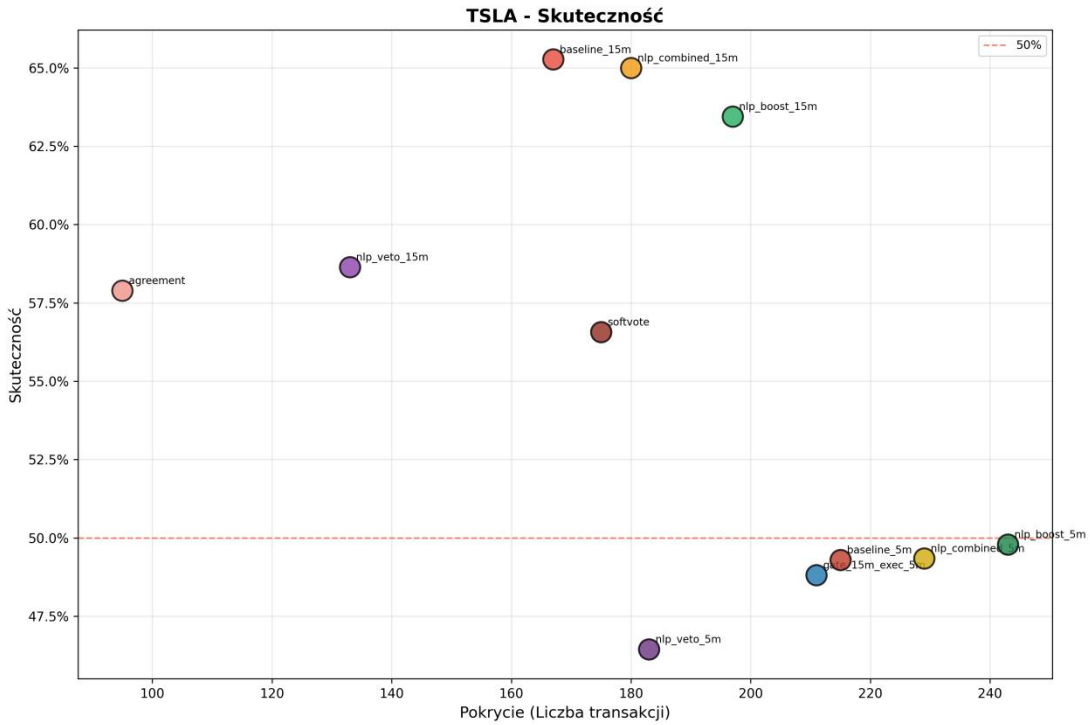

Rysunek 5.5. Wykres skuteczności strategii dla spółki TSLA
Źródło: opracowanie własne

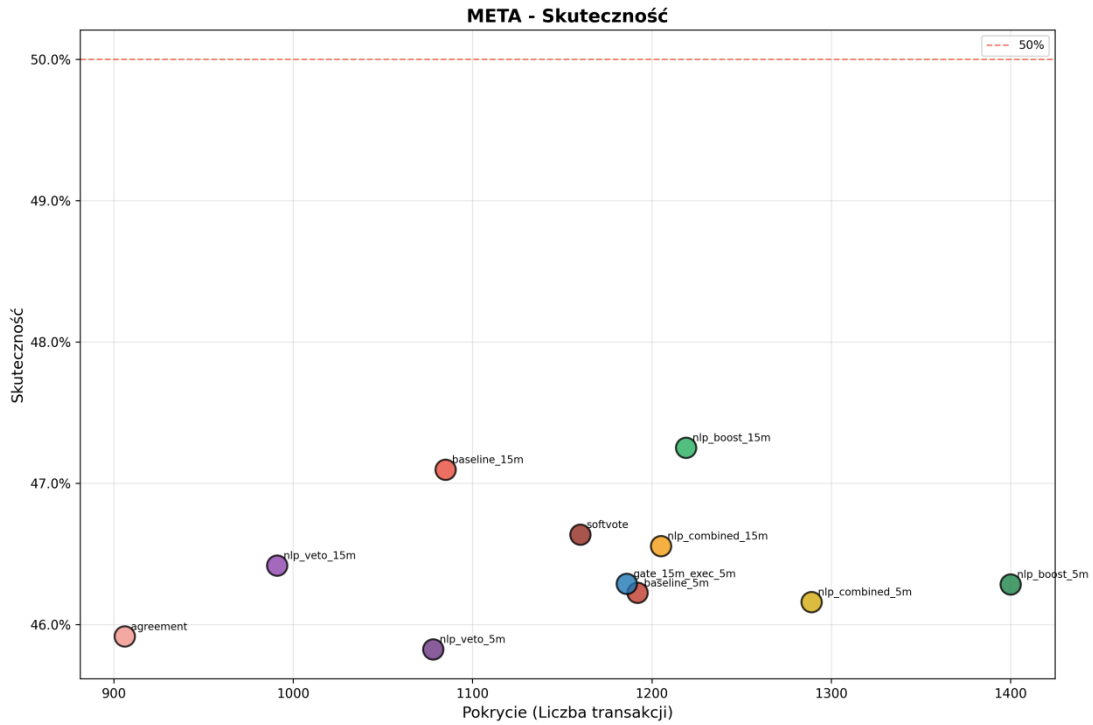

Rysunek 5.6. Wykres skuteczności strategii dla spółki META
Źródło: opracowanie własne

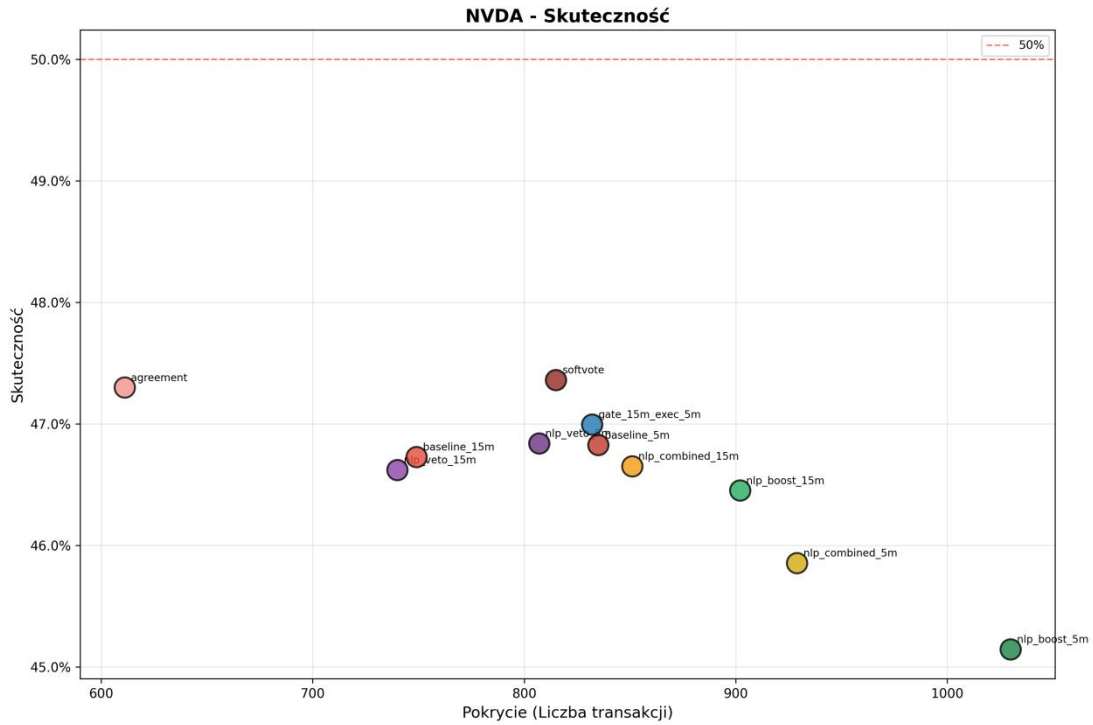

Rysunek 5.7. Wykres skuteczności strategii dla spółki NVDA
Źródło: opracowanie własne

Zestawienie wartości p testu dwumianowego dla wszystkich jedenastu strategii przedstawione w tabeli 5.4 wskazuje, że nielosowa zdolność predykcyjna jest zjawiskiem rzadkim i skoncentrowanym na wybranych instrumentach. Spośród łącznie 77 badanych

kombinacji jedynie 11 przekroczyło próg istotności równy 0,05(oznaczone *). Dla większości kombinacji testy nie dostarczyły podstaw do odrzucenia hipotezy o losowej skuteczności sygnałów, co wskazuje na trudność w wypracowaniu systematycznej przewagi predykcyjnej przy użyciu zastosowanych modeli na badanej próbie.

Zidentyfikowano jednak obszary gdzie testowane podejścia wykazały istotną statystycznie zdolność predykcyjną. Szczególnie wyraźne jest to dla spółki TSLA na interwale 15-minutowym, gdzie strategie baseline_15m, nlp_boost_15m, nlp_combined_15m oraz softvote uzyskały wartości p bliskie zeru, jednoznacznie odrzucając hipotezę o losowej skuteczności. Istotnym rezultatem jest również wpływ komponentu NLP na spółce GOOGL. Strategia baseline_5m nie wykraczała poza losową skuteczność z p=0,370, jednak po zastosowaniu mechanizmu boost zdolność predykcyjna modelu wzrosła na tyle że stała się statystycznie istotna przy p=0,024, co stanowi potwierdzenie wcześniejszej obserwacji o wartości dodanej integracji informacji sentymentowej z modelem sekwencyjnym.

Tabela 5.4. Istotność statystyczna skuteczności strategii dla analizowanych instrumentów

Strategia	AAPL	GOOGL	AMZN	MSFT	TSLA	META	NVDA
baseline_5m	0,039*	0,370	0,217	0,608	0,607	1	1
baseline_15m	0,121	0,500	0,678	0,476	0*	1	1
agreement	0,087	0,377	0,170	0,594	0,075	1	1
softvote	0,140	0,466	0,582	0,683	0,048*	1	1
gate_15m_exec_5m	0,046*	0,391	0,217	0,616	0,660	1	1
nlp_veto_5m	0,043*	0,375	0,151	0,775	0,850	1	1
nlp_veto_15m	0,085	0,653	0,548	0,623	0,028*	1	1
nlp_boost_5m	0,023*	0,024*	0,489	0,364	0,551	1	1
nlp_boost_15m	0,097	0,156	0,676	0,591	0*	1	1
nlp_combined_5m	0,099	0,262	0,177	0,424	0,604	1	1
nlp_combined_15m	0,226	0,307	0,662	0,555	0*	1	1

Źródło: opracowanie własne

Wyniki oscylujące wokół przyjętej granicy losowości nie przesądzają o braku użyteczności praktycznej prezentowanych modeli. Ocena rentowności systemu transakcyjnego nie może być sprowadzona wyłącznie do skuteczności klasyfikacji kierunkowej, gdyż w rzeczywistym tradingu równie istotnym czynnikiem determinującym wynik finansowy jest zarządzanie ryzykiem. Odpowiednie kształtowanie relacji zysku do ryzyka na pojedynczej transakcji może znacząco obniżyć próg rentowności systemu,

sprawiając że nawet model dysponujący jedynie marginalną przewagą informacyjną nad rynkiem jest w stanie generować dodatnie wyniki kapitałowe w długim horyzoncie.

Przy założeniu idealnego stosunku zysku do ryzyka wynoszącego 2:1, z pominięciem kosztów transakcyjnych, próg rentowności obniża się do poziomu ~33,3%, co oznacza że system pozostaje zyskowny już przy co trzeciej trafnej predykcji. W świetle tej zależności nawet strategie osiągające skuteczność na poziomach najniższych spośród zaobserwowanych w niniejszym badaniu dysponują wystarczającą przewagą, by przy właściwej dyscyplinie zarządzania pozycją generować dodatni wynik finansowy w długim terminie, co obrazują krzywe kapitału najgorszej z badanych spółek przedstawione na rysunku 5.8.

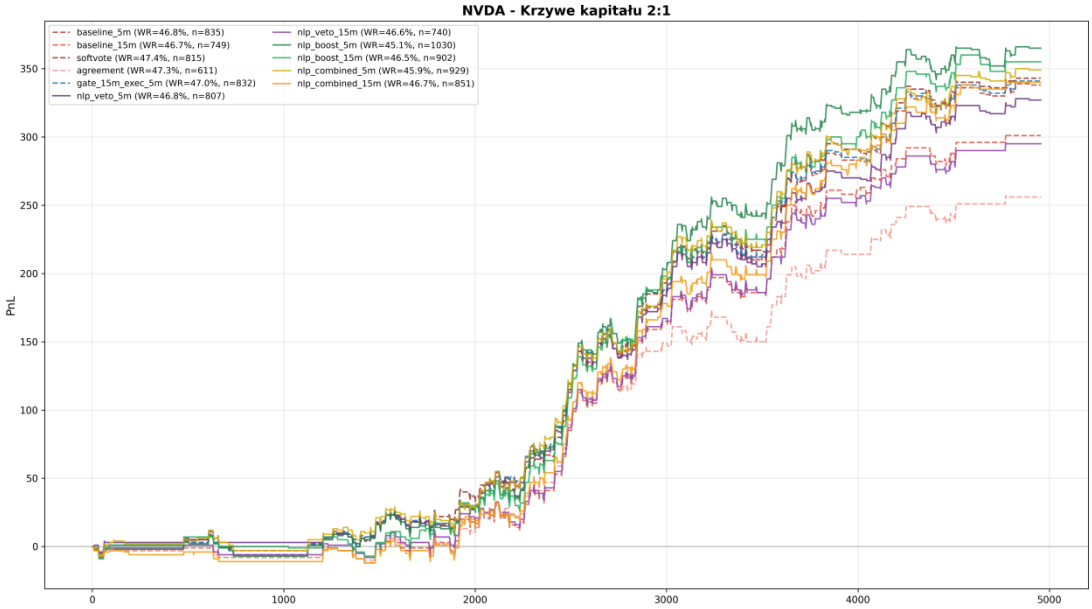

Rysunek 5.8. Symulacja krzywych kapitału dla spółki o najniższej skuteczności
Źródło: opracowanie własne

Spośród wszystkich zbadanych mechanizmów na szczególną uwagę zasługuje pozytywny sentyment informacyjny, którego zdolność do współwystępowania z kierunkowym ruchem cenowym została empirycznie potwierdzona i który wnosi realną wartość dodaną względem samodzielnych modeli sekwencyjnych. Jego głębsza integracja z analizą cenową, przy jednoczesnym zastosowaniu konsekwentnego zarządzania ryzykiem, wyznacza obiecującą ścieżkę ku budowie systemu transakcyjnego dysponującego mierzalną i powtarzalną przewagą nad rynkiem.

Zakończenie

Niniejsza praca podjęła problem krótkoterminowej predykcji kierunku zmian cen instrumentów finansowych, formułując go jako zadanie klasyfikacji trójklasowej realizowane przez system łączący modelowane dane cenowe sekwencyjnie przy użyciu sieci LSTM z komponentem analizy sentymentu opartym na modelu FinBERT.

Hipoteza główna zakładająca osiągnięcie trafności predykcji wyższej niż przypadkowa klasyfikacja została potwierdzona. Oba modele sekwencyjne przekroczyły próg losowości oraz wynik naiwnego klasyfikatora, uzyskując dokładność 50,43% dla interwału 5-minutowego i 52,78% dla interwału 15-minutowego. Zdolność predykcyjna znalazła potwierdzenie również na etapie inferencji. W kontekście dwuklasowego problemu decyzyjnego szereg strategii osiągnął skuteczność wyższą niż losowa przy czym wyniki te były bardziej zróżnicowane i zależne od danego instrumentu.

Pierwsza hipoteza poboczna dotycząca skuteczności prostego łączenia modeli sekwencyjnych z różnych interwałów czasowych nie została potwierdzona. Żadna z badanych metod fuzji nie wykazała systematycznej przewagi nad lepszym z modeli bazowych, co wskazuje że sama kombinacja sygnałów modeli różniących się skutecznością nie jest wystarczającym warunkiem poprawy jakości predykcji. Naiwne metody łączenia przynoszą wartość jedynie wtedy, gdy oba modele bazowe są porównywalnie skuteczne, co w przeprowadzonym badaniu było wyjątkiem.

Druga hipoteza poboczna dotycząca pozytywnego wpływu informacji tekstowych na skuteczność klasyfikacji kierunku zmian cen została potwierdzona częściowo. Integracja pozytywnego sentymentu z modelami sekwencyjnymi przełożyła się na poprawę jakości sygnałów na części analizowanych instrumentów, natomiast mechanizm oparty na negatywnym sentymencie nie wykazał symetrycznej wartości predykcyjnej. Ujawnia to pewną asymetrię w tym, jak informacja tekstowa przekłada się na sygnał predykcyjny, choć wynik ten nie przesądza o braku wartości dodanej negatywnego sentymentu jako takiego, może on wynikać ze specyfiki zastosowanego mechanizmu veto i dobranego progu, a nie z braku predykcyjnego potencjału negatywnego nastroju rynkowego. Rynkowa absorpcja informacji pozytywnych i negatywnych ma odmienny charakter dynamiki. Zatem systemy predykcyjne nie mogą traktować optymizmu i pesymizmu jako symetrycznych sił, lecz muszą modelować je jako dwa niezależne procesy o różnej wrażliwości.

Przeprowadzone badanie potwierdza, że krótkoterminowa predykcja kierunku zmian cen pozostaje dużym wyzwaniem, jednak zastosowanie metod uczenia maszynowego pozwala na uzyskanie wymiernej przewagi informacyjnej. Wypracowane podejście dostarcza empirycznych podstaw do rozwoju systemów łączących analizę cenową z

informacją tekstową, a zidentyfikowane w pracy ograniczenia wyznaczają naturalny kierunek dla przyszłych badań i optymalizacji.

Streszczenie w języku polskim

Praca dotyczy budowy systemu predykcji krótkoterminowych ruchów cenowych akcji spółek z grupy „Magnificent Seven” przy użyciu modeli sekwencyjnych LSTM wzbogaconych o analizę sentymentu wiadomości finansowych. Teoretyczną podstawę pracy stanowi analiza mechanizmów rynkowych, ograniczeń hipotezy efektywnego rynku oraz roli analizy technicznej i sentymentu inwestorów jako źródeł informacji predykcyjnej.

Dane cenowe w interwałach 5-minutowych oraz wiadomości rynkowe pozyskano z API EODHD dla okresu 2020–2026, a kierunek ruchu cenowego etykietowano metodą trzech barier, wyróżniającą klasy wzrostowe spadkowe i konsolidacyjne.

Zbudowano dwa modele LSTM trenowane na starannie wyselekcjonowanych cechach, obejmujących podstawowe grupy wskaźników analizy technicznej. Na etapie inferencji przetestowano 11 strategii decyzyjnych dla każdej ze spółek, analizując warianty łączące sygnały obu modeli sekwencyjnych między sobą oraz rozszerzenia wzbogacone o komponent sentymentu obliczany przez model FinBERT.

Wyniki badań potwierdziły główne założenie, wykazując, że wypracowane modele sekwencyjne potrafią skutecznie wyodrębnić sygnały z szeregów czasowych, osiągając trafność predykcji wyższą niż klasyfikacja losowa. Udowodniono jednocześnie, że naiwne metody łączenia modeli sekwencyjnych z różnych interwałów nie przynoszą systematycznej wartości dodanej. Z kolei integracja pozytywnego sentymentu informacyjnego przełożyła się na realną wartość predykcyjną, szczególnie dla spółek AAPL, GOOGL i TSLA. Potwierdza to użyteczność łączenia analizy cenowej z przetwarzaniem języka naturalnego oraz wytycza obiecujący kierunek dla dalszego rozwoju hybrydowych systemów wspomagania decyzji inwestycyjnych.

Streszczenie w języku angielskim

This thesis focuses on developing a short-term price movement prediction system for the "Magnificent Seven" stocks using LSTM sequential models enriched with the sentiment analysis of financial news. The theoretical foundation of the study comprises an analysis of market mechanisms, the limitations of the efficient market hypothesis, and the role of technical analysis and investor sentiment as sources of predictive information.

Price data in 5-minute intervals, along with market news, were acquired from the EODHD API for the period 2020–2026. The direction of price movements was labeled using the triple-barrier method, distinguished between upward, downward, and consolidation classes.

Two LSTM models were built and trained on carefully selected features encompassing the primary groups of technical analysis indicators. During the inference stage, 11 decision strategies were tested for each company, analyzing variants that combined signals from both sequential models, as well as extensions enriched with the sentiment component calculated by the FinBERT model.

The research results confirmed the main hypothesis, demonstrating that the developed sequential models can effectively extract signals from time series, achieving a prediction accuracy higher than random classification. Simultaneously, it was proven that naive methods of combining sequential models from different time intervals do not bring systematic added value. The integration of positive informational sentiment translated into real predictive value, particularly for AAPL, GOOGL, and TSLA stocks. This confirms the utility of combining price analysis with natural language processing and outlines a promising direction for the further development of hybrid investment decision support systems.

Bibliografia

1. Dębski W., Rynek finansowy i jego mechanizmy. Wydawnictwo Naukowe PWN, 2014
2. Mishkin F.S., Ekonomika pieniądza, bankowości i rynków finansowych. Wydawnictwo Naukowe PWN, 2017
3. Fama E.F., Efficient Capital Markets: A Review of Theory and Empirical Work. The Journal of Finance, 1970
4. Rosenthal L., Young C., The Seemingly Anomalous Price Behavior of Royal Dutch/Shell and Unilever N.V./PLC. Journal of Financial Economics, 1990
5. Shleifer A., Vishny R.W., The Limits of Arbitrage. The Journal of Finance, 1997
6. Murphy J.J., Technical Analysis of the Financial Markets: A Comprehensive Guide to Trading Methods and Applications. New York Institute of Finance, 1999
7. Shiller R.J., Irracjonalny optymizm. Studio Emka, 2004
8. Tetlock P.C., Giving Content to Investor Sentiment: The Role of Media in the Stock Market. The Journal of Finance, 2007
9. Baker M., Wurgler J., Investor Sentiment and the Cross-Section of Stock Returns. The Journal of Finance, 2006
10. Goodfellow I., Bengio Y., Courville A., Deep Learning. MIT Press, 2016
11. Bengio Y., Simard P., Frasconi P., Learning Long-Term Dependencies with Gradient Descent Is Difficult. IEEE Transactions on Neural Networks, 1994
12. Hochreiter S., Schmidhuber J., Long Short-Term Memory. Neural Computation, 1997
13. Kandadi T., Shankarlingam G., Drawbacks of LSTM Algorithm: A Case Study. SSRN, 2025
14. Bahdanau D., Cho K., Bengio Y., Neural Machine Translation by Jointly Learning to Align and Translate. ICLR, 2015
15. Loughran T., McDonald B., When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks. The Journal of Finance, 2011
16. Vaswani A. et al., Attention Is All You Need. NeurIPS, 2017
17. Devlin J., Chang M.W., Lee K., Toutanova K., BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT, 2019
18. Huang A.H., Wang H., Yang Y., FinBERT: A Large Language Model for Extracting Information from Financial Text. Contemporary Accounting Research, 2023
19. Liu Y., Tsyvinski A., Risks and Returns of Cryptocurrency. The Review of Financial Studies, 2021
20. Mantegna R.N., Hierarchical Structure in Financial Markets. The European Physical Journal B, 1999

21. Lo A.W., Adaptive Markets: Financial Evolution at the Speed of Thought. Princeton University Press, 2017
22. Chen J., Order Spoofing, Price Impact, and Market Quality. Pacific-Basin Finance Journal, 2026
23. The Financial Edits, 70+ Technical Indicators - Mastering Intraday Trading. Mocktime Publication, 2023
24. Murphy J.J., Technical Analysis of the Financial Markets. New York Institute of Finance, 1999
25. Kaufman P.J., Trading Systems and Methods. Wiley, 2013
26. Regenstein Jr. J.K., Reproducible Finance with R: Code Flows and Shiny Apps for Portfolio Analysis. CRC Press, 2018
27. Lim M.A., The Handbook of Technical Analysis. Wiley, 2015
28. Amihud Y., Mendelson H., Pedersen L.H., Liquidity and Asset Prices. Now Publishers, 2006
29. López de Prado M., Advances in Financial Machine Learning. Wiley, 2018
30. Hendrycks D., Gimpel K., Gaussian Error Linear Units (GELUs), 2016
31. Abdi H., Williams L.J., Normalizing data. Encyclopedia of Research Design, 2010
32. Kingma D.P., Ba J., Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980, 2014
33. Rami S., Predictability of Stock Price Fluctuations with an Application of Agricultural Companies Data. American Journal of Business and Operations Research, 2025

Strony www

34. https://www.xtb.com/en/education/trading-with-the-trend
35. https://www.investopedia.com/terms/m/marketsentiment.asp
36. https://colah.github.io/posts/2015-08-Understanding-LSTMs
37. https://thorirmar.com/post/insight_into_lstm

Spis rysunków

Rysunek 1.1. Schemat trzech stanów rynku: wzrostu, konsolidacji i spadku 15
Rysunek 1.2. Korelacja między wskaźnikiem pesymizmu a ceną indeksu S&P500 18
Rysunek 2.1. Architektura prostej sieci RNN 22
Rysunek 2.2. Architektura komórki lstm 24
Rysunek 3.1. Metoda klasyfikacji kierunku trzech barier 47
Rysunek 4.1. Architektura modelu sekwencyjnego 50
Rysunek 4.2. Diagram kalibracji modelu 5-minutowego 58
Rysunek 4.3. Diagram kalibracji modelu 15-minutowego 59
Rysunek 4.4. Analiza ważności cech modelu 5-minutowego 60
Rysunek 4.5. Analiza ważności cech modelu 15-minutowego 61
Rysunek 5.1. Wykres skuteczności strategii dla spółki AAPL 70
Rysunek 5.2. Wykres skuteczności strategii dla spółki GOOGL 71
Rysunek 5.3. Wykres skuteczności strategii dla spółki AMZN 71
Rysunek 5.4. Wykres skuteczności strategii dla spółki MSFT 72
Rysunek 5.5. Wykres skuteczności strategii dla spółki TSLA 72
Rysunek 5.6. Wykres skuteczności strategii dla spółki META 73
Rysunek 5.7. Wykres skuteczności strategii dla spółki NVDA 73
Rysunek 5.8. Symulacja krzywych kapitału dla spółki o najniższej skuteczności 75

Spis tabel

Tabela 3.1. Reguły agregacji świec z interwału bazowego do wyższego interwału czasowego 34
Tabela 3.2. Mapowanie kategorii analizy technicznej na zaimplementowane wskaźniki 35
Tabela 4.1. Wyniki raportu klasyfikacyjnego modelu 5-minutowego 57
Tabela 4.2. Wyniki raportu klasyfikacyjnego modelu 15-minutowego 57
Tabela 5.1. Zestawienie wariantów strategii decyzyjnych wraz ze źródłami sygnału 65
Tabela 5.2. Wartości podstawowych progów decyzyjnych strategii 66
Tabela 5.3. Wartości progów sentymentowych 67
Tabela 5.4. Istotność statystyczna skuteczności strategii dla analizowanych instrumentów . 74

Załącznik 1. Płyta CD. Kody źródłowe aplikacji: moduł przygotowawczy, moduł główny